

Trabajo Final — Opción Dataset Propio

Un recorrido completo por las unidades de la materia sobre datos elegidos por el estudiante

1. Introducción

A diferencia de las otras opciones del trabajo final, que replican un paper sobre un dataset fijo, esta opción es **abierta**: el estudiante elige su propio conjunto de datos y lo recorre de punta a punta aplicando las técnicas vistas en la materia.

El objetivo no es lograr el mejor modelo posible, sino **demostrar criterio**. En cada etapa el estudiante debe:

- Aplicar una técnica vista en clase sobre su dataset.
- Justificar por qué eligió esa técnica y, sobre todo, **por qué descartó las alternativas vistas** en la materia.
- Investigar de forma autónoma una técnica que quedó **fuera del programa** y explicarla brevemente (una o dos slides). Las técnicas investigadas **no se aplican**: solo se explican en el informe.

2. Elección del dataset

El estudiante elige libremente su dataset, pero este debe cumplir condiciones mínimas para que sea posible recorrer todas las unidades de la materia con él:

- **Variable objetivo (target)**: debe tener al menos una variable que sirva como objetivo de un modelo supervisado (categórica para clasificación o numérica para regresión).
- **Variables explicativas**: al menos 6–8 variables predictoras, para que la reducción de dimensión, la imputación y la exploración tengan sentido.
- **Tamaño**: al menos unas 500 observaciones (filas), para que la partición en *train/test* sea razonable.
- **Originalidad**: no puede ser uno de los datasets “juguete” de **sklearn** (Iris, Wine, Breast Cancer, Digits, etc.) ni el CICIDS-2017 usado en las otras opciones.
- **Realismo**: idealmente que presente algo de “suciedad” real (valores faltantes, variables de distinto tipo, escalas dispares), para que la etapa de preparación no sea trivial.

En el informe se debe incluir una breve descripción del dataset: origen, cantidad de filas y columnas, tipos de variables, significado de la variable objetivo y por qué resulta interesante de analizar.

3. Estructura del trabajo por bloques

El trabajo se organiza en cinco bloques, que siguen las unidades de la materia. En cada bloque, salvo que se indique lo contrario, el estudiante **aplica** una técnica vista (justificando su elección y el descarte de las alternativas vistas) y además **investiga** una técnica fuera del programa, que solo explica (no aplica). La investigación es libre: la idea es que el estudiante explore por su cuenta qué existe más allá de lo visto, no que complete una lista cerrada.

Bloque 1 — Obtención y preparación de datos (U1)

Aplicar: carga y limpieza del dataset, tratamiento de valores faltantes con un método visto, escalado o normalización de variables numéricas, codificación de variables categóricas. Justificar cada decisión y por qué se descartaron las otras opciones vistas (por ejemplo: ¿por qué mediana y no media? ¿por qué estandarizar y no normalizar?).

Investigar (explicar, no aplicar): un método de **tratamiento de valores faltantes** más sofisticado que los vistos en la materia. Explicar en qué consiste y en qué situaciones aportaría respecto de la imputación simple.

Bloque 2 — Exploración y visualización (U2)

Aplicar: un análisis exploratorio (EDA) con los gráficos vistos en clase. Justificar qué gráfico usa para responder qué pregunta, y por qué ese y no otro de los vistos.

Investigar (explicar, no aplicar): un **tipo de gráfico exploratorio** que no se vio en la materia. Explicar qué tipo de información permite ver y en qué caso sería preferible a los vistos.

Bloque 3 — Modelado estadístico y aprendizaje supervisado (U3 + U4)

Aplicar: al menos un modelo supervisado visto en clase (regresión lineal, regresión logística, o un clasificador visto), con su evaluación correspondiente (métricas, partición *train/test*, interpretación de coeficientes o de la importancia de variables). Justificar la elección del modelo según el tipo de problema y de variable objetivo, y por qué se descartaron los otros modelos vistos.

Investigar (explicar, no aplicar): un **modelo supervisado** que no se vio en la materia. Explicar su idea principal y en qué se diferenciaría del modelo aplicado.

Bloque 4 — Aprendizaje no supervisado (U5)

Aplicar: una técnica no supervisada vista en clase (clustering o reducción de dimensión), interpretando los resultados sobre su dataset. Justificar la elección y el descarte de las alternativas vistas (por ejemplo: ¿cómo eligió el número de clusters?).

Investigar (explicar, no aplicar): una **técnica no supervisada** que no se vio en la materia. Explicar su idea y en qué se diferencia de la técnica aplicada.

Bloque 5 — Predicción y comunicación de resultados (U6)

Aplicar: una síntesis visual y narrativa de los resultados del trabajo, con las herramientas de comunicación vistas en clase: gráficos finales claros, interpretación de los hallazgos y conclusiones para una audiencia no técnica. Justificar qué resultados decide destacar y por qué.

Este bloque no lleva parte de investigación: es el cierre del recorrido.

4. Implementación

El desarrollo se organiza en **varios notebooks**, numerados por orden de ejecución y ubicados en la carpeta `notebooks/` del repositorio (por ejemplo, uno por bloque: `01_preparacion.ipynb`, `02_exploracion.ipynb`, etc., o el agrupamiento que el estudiante considere más claro). Cada notebook debe ser **reproducible** y **auto-contenido**: cualquier persona debe poder ejecutarlo de principio a fin sin intervención manual, y las celdas de texto (markdown) deben explicar cada etapa, incluyendo las justificaciones pedidas en cada bloque. El dataset debe quedar accesible en la carpeta `data/` del repositorio o ser descargable desde una URL pública indicada en el código.

5. Hilo conductor y conclusiones

El trabajo no debe leerse como cinco ejercicios sueltos, sino como un **recorrido coherente** sobre un mismo dataset. En la conclusión, el estudiante debe responder:

- ¿Qué aprendió sobre su dataset a lo largo del recorrido?
- De las técnicas que investigó por su cuenta, ¿cuál le pareció más prometedora para sus datos y por qué?
- Si tuviera que seguir trabajando este dataset, ¿qué haría a continuación?

6. Estructura del repositorio (entrega en GitHub)

El trabajo se entrega como un repositorio de GitHub, siguiendo la estructura de proyecto vista en la Unidad 6 (Bloque 5: Portfolio profesional):

<code>mi_proyecto/</code>	
<code> README.md</code>	
<code> data/</code>	
<code>raw/</code>	(datos originales, nunca modificados)
<code>processed/</code>	(datos limpios, listos para modelar)
<code> notebooks/</code>	(numerados por orden de ejecución)
<code> src/</code>	
<code>utils.py</code>	(funciones reutilizables)
<code> reports/</code>	(la presentación Beamer compilada)
<code> requirements.txt</code>	

El `README.md` debe seguir las siete secciones mínimas vistas en clase: (1) título y descripción breve; (2) motivación; (3) datos (origen, tamaño, variables principales); (4) metodología (qué técnicas se usaron y por qué); (5) resultados principales; (6) cómo ejecutar; (7) limitaciones y próximos pasos.

Si los datos son grandes o sensibles, subir solo una muestra o las instrucciones para obtenerlos.

7. Informe en formato Beamer

El informe del trabajo se entrega **en formato de presentación Beamer** (no como documento de texto corrido). Debe tener entre **20 y 30 slides** y seguir el recorrido del trabajo:

1. **Portada.** Título, nombre del estudiante, dataset elegido, curso y fecha.
2. **Presentación del dataset.** Origen, variables, variable objetivo, por qué es interesante.
3. **Preparación (U1).** Decisiones de limpieza e imputación, con justificación. Slide(s) con la técnica investigada.
4. **Exploración (U2).** Hallazgos del EDA. Slide(s) con el gráfico investigado.
5. **Modelado supervisado (U3+U4).** Modelo aplicado con métricas. Slide(s) con el modelo investigado.
6. **No supervisado (U5).** Técnica aplicada e interpretación. Slide(s) con la técnica investigada.
7. **Comunicación y conclusiones (U6).** Síntesis visual, qué se aprendió del dataset y de las técnicas nuevas.

La presentación debe entregarse como archivo .tex y .pdf, y debe ser auto-contenida: alguien que no haya visto el notebook debe poder comprender el trabajo leyendo solo las slides.

8. Entregables

El trabajo se entrega como un **repositorio de GitHub** con la estructura de la sección 4, que debe contener:

- Los **notebooks** completos y reproducibles, numerados por orden de ejecución (en **notebooks/**).
- El **dataset** utilizado, o las instrucciones para obtenerlo (en **data/**).
- El informe en **Beamer**: archivos .tex y .pdf (el .pdf en **reports/**).
- El **README.md** con las siete secciones.
- El archivo **requirements.txt** con las dependencias.
- **tpfinal_mad1_dataset_propio_chat.json** — Conversación completa con la herramienta de IA utilizada. (NO SE SUBE AL REPOSITORIO, SINO QUE SE ENVIA POR MAIL)

9. Documentación del uso de IA

El uso de herramientas de IA (ChatGPT, Claude, etc.) está permitido durante el desarrollo del trabajo.

- Utilizar una **única sesión de chat** para todo el desarrollo del trabajo, de principio a fin.
- Al finalizar, exportar esa conversación completa y entregarla junto con el resto de los archivos. En ChatGPT: Configuración → Exportar datos, se entrega el archivo **conversations.json**. Alternativamente, el chat en texto plano.
- Nombrar el archivo como **tpfinal_mad1_dataset_propio_chat.json** (o .txt).

10. Criterios de evaluación

La mitad de la nota depende del **Jupyter Notebook**, evaluado en base a:

- Reproducibilidad: el notebook corre de principio a fin sin intervención.
- Auto-contenido: las celdas markdown explican y justifican cada etapa.
- **Calidad de las justificaciones:** por qué se eligió cada técnica y por qué se descartaron las alternativas vistas. Este es el corazón de esta opción.
- Investigación autónoma: las técnicas fuera del programa están bien comprendidas y explicadas.
- Coherencia: el trabajo se lee como un recorrido único, no como ejercicios sueltos.

La otra mitad depende del **informe en Beamer**, evaluado en base a:

- Claridad: cada slide transmite una sola idea principal.
- Explicabilidad: las técnicas (aplicadas e investigadas) quedan explicadas para alguien que no las conoce.
- Auto-contenido: la presentación se entiende sola, sin el notebook.
- Calidad de la presentación: uso correcto del template, sin exceso de texto.

La organización del repositorio (estructura de carpetas y README) también se considera en la evaluación, en línea con lo visto en la Unidad 6.

A criterio del docente, se podrá solicitar una presentación oral como instancia de desempate o verificación.