Métodos de Análisis de Datos 1

Clase 1: El Ciclo de Análisis de Datos

Universidad Nacional del Sur

Contenidos de hoy

1. Información del curso
2. ¿Qué es el análisis de datos?
3. El ciclo de análisis de datos
4. Tipos de análisis
5. Roles en ciencia de datos
6. Configuración del entorno
7. Resumen

Información del curso

- **Modalidad:** Presencial
- **Horario:** Lunes y miércoles
- **Duración:** 30 clases (16 marzo - 3 julio)
- **Herramientas:** Python, R, VS Code, Jupyter

Evaluación

- Sin parciales escritos
- Entrega de Proyecto integrador al final del curso
- Github personal para subir tareas y proyecto

Objetivos del curso

Al finalizar el curso serán capaces de:

- Aplicar el **ciclo completo** de análisis de datos
- Utilizar **Python y R** para análisis de datos
- Construir y evaluar **modelos** estadísticos y de ML
- **Comunicar** hallazgos mediante visualizaciones y reportes
- Trabajar con **datos reales** de diversas fuentes

¿Qué es el análisis de datos?

Definición

El **análisis de datos** es el proceso de inspeccionar, limpiar, transformar y modelar datos con el objetivo de:

- Descubrir información útil
- Informar conclusiones
- Apoyar la toma de decisiones

¿Qué es el análisis de datos?

Definición

El **análisis de datos** es el proceso de inspeccionar, limpiar, transformar y modelar datos con el objetivo de:

- Descubrir información útil
- Informar conclusiones
- Apoyar la toma de decisiones

Ejemplo

Una empresa de e-commerce quiere entender por qué bajaron las ventas:

- ¿Qué productos tienen mayor abandono del carrito?
- ¿Qué clientes tienen mayor probabilidad de comprar?
- ¿Qué acciones aumentarían las ventas?

El ciclo de análisis de datos

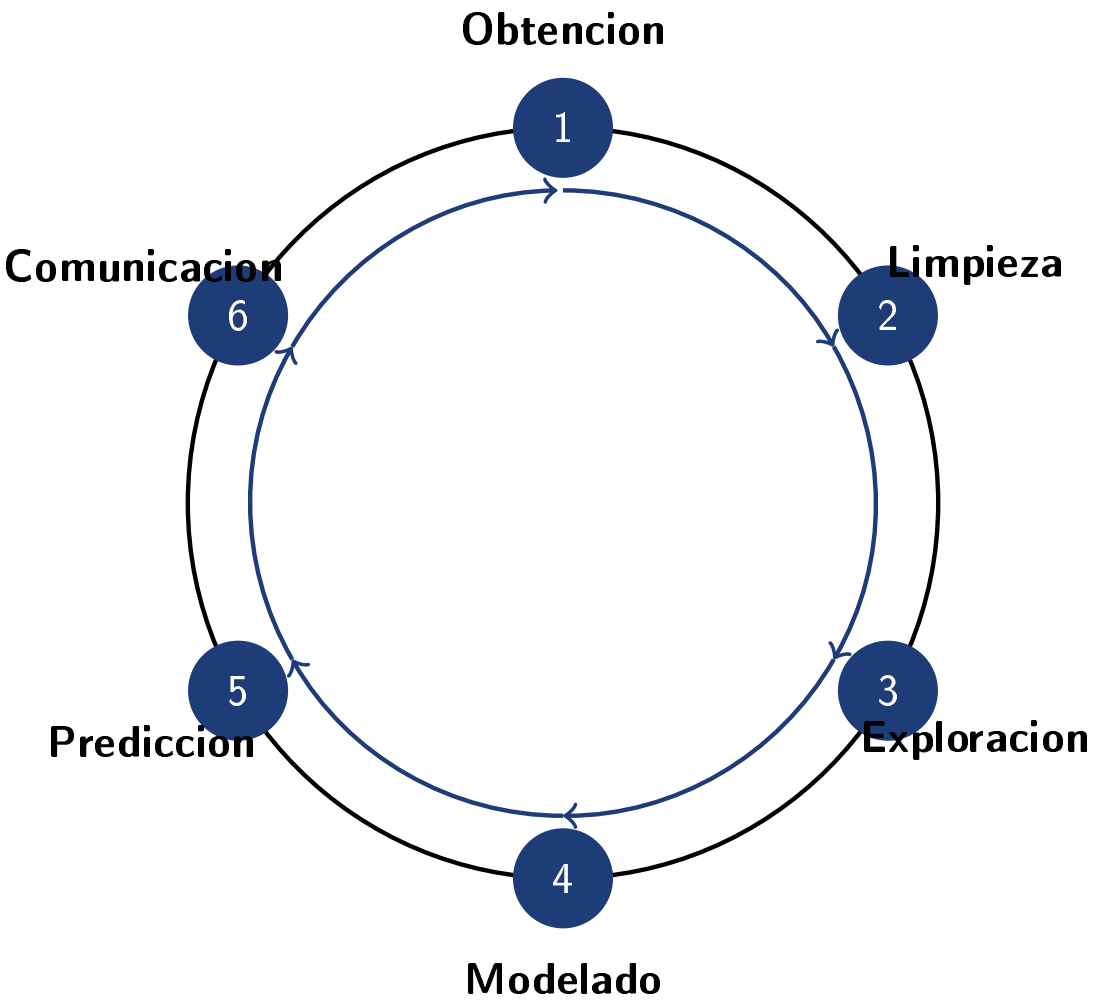

El ciclo es iterativo: podemos volver a etapas anteriores

Etapas del ciclo

1. **Obtención:** Acceder a datos (archivos, APIs, bases de datos, web scraping)

Etapas del ciclo

1. **Obtención:** Acceder a datos (archivos, APIs, bases de datos, web scraping)
2. **Limpieza:** Corregir errores, tratar valores faltantes, transformar

Etapas del ciclo

1. **Obtención:** Acceder a datos (archivos, APIs, bases de datos, web scraping)
2. **Limpieza:** Corregir errores, tratar valores faltantes, transformar
3. **Exploración:** Estadística descriptiva y visualizaciones

Etapas del ciclo

1. **Obtención:** Acceder a datos (archivos, APIs, bases de datos, web scraping)
2. **Limpieza:** Corregir errores, tratar valores faltantes, transformar
3. **Exploración:** Estadística descriptiva y visualizaciones
4. **Modelado:** Construir modelos para responder preguntas

Etapas del ciclo

1. **Obtención:** Acceder a datos (archivos, APIs, bases de datos, web scraping)
2. **Limpieza:** Corregir errores, tratar valores faltantes, transformar
3. **Exploración:** Estadística descriptiva y visualizaciones
4. **Modelado:** Construir modelos para responder preguntas
5. **Predicción:** Aplicar modelos a nuevos datos

Etapas del ciclo

1. **Obtención:** Acceder a datos (archivos, APIs, bases de datos, web scraping)
2. **Limpieza:** Corregir errores, tratar valores faltantes, transformar
3. **Exploración:** Estadística descriptiva y visualizaciones
4. **Modelado:** Construir modelos para responder preguntas
5. **Predicción:** Aplicar modelos a nuevos datos
6. **Comunicación:** Presentar hallazgos de forma clara

Tipos de análisis de datos

Descriptivo

¿Qué pasó?
Estadísticas resumidas y visualizaciones
Ej: "Las ventas fueron $50,000"

Inferencial

¿Podemos generalizar?
Inferencias con incertidumbre
Ej: "El descuento aumenta ventas 10-25 %"

Exploratorio (EDA)

¿Qué patrones hay?
Buscar relaciones y tendencias
Ej: "Ventas bajan los fines de semana"

Predictivo

¿Qué pasará?
Modelos para el futuro
Ej: "Cliente X comprará con 78 % prob."

Análisis causal

Causal: ¿Qué causó este resultado?

- Identifica relaciones de **causa-efecto**
- Diferencia **correlación** de **causalidad**

Ejemplo

"El aumento del precio **causó** una disminución del 12 % en la demanda" (controlando por estacionalidad y competencia)

Correlación $\neq$ Causalidad

Roles en ciencia de datos

- **Analista de datos**
  - Análisis descriptivo y exploratorio
  - Reportes y dashboards
  - SQL, Excel, herramientas de BI

Roles en ciencia de datos

- **Analista de datos**
  - Análisis descriptivo y exploratorio
  - Reportes y dashboards
  - SQL, Excel, herramientas de BI
- **Científico de datos**
  - Modelos predictivos, machine learning
  - Experimentación, A/B testing
  - Python, R, estadística avanzada

Roles en ciencia de datos

- **Analista de datos**
  - Análisis descriptivo y exploratorio
  - Reportes y dashboards
  - SQL, Excel, herramientas de BI
- **Científico de datos**
  - Modelos predictivos, machine learning
  - Experimentación, A/B testing
  - Python, R, estadística avanzada
- **Ingeniero de datos**
  - Infraestructura, pipelines, ETL
  - Bases de datos, data warehouses
  - SQL, Spark, Airflow

Roles en ciencia de datos

- **Analista de datos**
  - Análisis descriptivo y exploratorio
  - Reportes y dashboards
  - SQL, Excel, herramientas de BI
- **Científico de datos**
  - Modelos predictivos, machine learning
  - Experimentación, A/B testing
  - Python, R, estadística avanzada
- **Ingeniero de datos**
  - Infraestructura, pipelines, ETL
  - Bases de datos, data warehouses
  - SQL, Spark, Airflow
- **Ingeniero de ML**
  - Modelos en producción
  - Escalabilidad, monitoring
  - MLOps, deployment

Herramientas del curso

Python + Anaconda

- Descarga: `anaconda.com`
- Incluye: pandas, numpy, scikit-learn, matplotlib, seaborn
- Gestores: `conda` y `pip`

R + RStudio

- R: `cran.r-project.org`
- RStudio: `posit.co`
- Librerías: tidyverse, ggplot2, caret

Visual Studio Code

- Descarga: `code.visualstudio.com`
- Extensiones: Python, Jupyter, R
- Interfaz principal para notebooks

Git y GitHub

Git

- Control de versiones local
- Descarga: `git-scm.com`
- Rastrea cambios, colaboración

GitHub

- Plataforma web para repositorios
- Crear cuenta: `github.com`
- Alojar código, colaborar, compartir

Tarea para hoy

1. Instalar Anaconda (Python)
2. Instalar R y RStudio
3. Instalar VS Code + extensiones

Resumen de la clase

- El análisis de datos sigue un **ciclo iterativo**
- Diferentes tipos: descriptivo, exploratorio, inferencial, predictivo, causal
- Diferentes roles: analista, científico, ingeniero de datos/ML
- Herramientas: **Python, R, VS Code, Git, GitHub**

Próxima clase

- Introducción a Jupyter notebooks
- Sintaxis básica de Python y R
- Buenas prácticas y reproducibilidad
- Caso de estudio: dataset Iris