Métodos de Análisis de Datos 1

Clase 8: Estadística Descriptiva Univariada

Depto. de Matemática – UNS

Universidad Nacional del Sur

1er Cuatrimestre 2026

Contenidos

1. Introducción
2. Medidas de posición central
3. Medidas de dispersión
4. Medidas de forma
5. Tablas de frecuencia
6. Resumen

Contenidos

1. Introducción
2. Medidas de posición central
3. Medidas de dispersión
4. Medidas de forma
5. Tablas de frecuencia
6. Resumen

¿Qué es la estadística descriptiva?

Objetivo

Resumir y describir las características principales de un conjunto de datos, sin extrapolaciones ni inferencias sobre la población.

- Es el primer paso en cualquier análisis de datos.
- Permite detectar patrones, valores atípicos y distribuciones.
- Se aplica **variable por variable** (análisis univariado).

Distinción clave

Estadística **descriptiva**: resume los datos observados. Estadística **inferencial**: generaliza a la población.

Tipos de variables

Variables cualitativas (categóricas)

- *Nominales*: sin orden.
  Ej.: sexo, grupo sanguíneo.
- *Ordinales*: con orden.
  Ej.: nivel educativo, estadio clínico.

Variables cuantitativas (numéricas)

- *Discretas*: valores contables.
  Ej.: número de hijos.
- *Continuas*: cualquier valor en un rango.
  Ej.: presión arterial, edad exacta.

Importancia

El tipo de variable determina qué medidas y gráficos son adecuados.

Contenidos

1 Introducción

2 Medidas de posición central

3 Medidas de dispersión

4 Medidas de forma

5 Tablas de frecuencia

6 Resumen

Media aritmética

Dado un conjunto de n observaciones $x_1, x_2, \ldots, x_n$:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i$$

- Es la medida de tendencia central más usada.
- **Sensible** a valores extremos (outliers).
- Para datos agrupados: $\bar{x} = \frac{\sum f_i m_i}{\sum f_i}$, donde m_i es la marca de clase.

Ejemplo

Edades: 25, 30, 28, 35, 22. $\bar{x} = \frac{140}{5} = 28$ años.

Mediana y Moda

Mediana (Me)

Valor que divide la distribución ordenada en dos mitades iguales.

- n impar: $Me = x_{(n+1)/2}$
- n par: $Me = \dfrac{x_{n/2} + x_{n/2+1}}{2}$

Ventaja: robusta frente a outliers.

Moda (Mo)

Valor (o clase) que aparece con mayor frecuencia.

- Puede no ser única: distribuciones bimodales o multimodales.
- Única medida aplicable a variables nominales.

Cuantiles

Los **cuantiles** dividen la distribución ordenada en partes iguales:

- **Cuartiles** (Q_1, Q_2, Q_3): dividen en 4 partes. $Q_2 = Me$.
- **Deciles** $(D_1, \ldots, D_9)$: dividen en 10 partes.
- **Percentiles** $(P_1, \ldots, P_{99})$: dividen en 100 partes.

Método de cálculo

Para el percentil p: calcular $L = p/100 \cdot n$. Si L es entero, $P_p = (x_{(L)} + x_{(L+1)})/2$; si no, $P_p = x_{(\lceil L \rceil)}$.

Contenidos

1 Introducción

2 Medidas de posición central

3 Medidas de dispersión

4 Medidas de forma

5 Tablas de frecuencia

6 Resumen

Varianza y desvío estándar

Varianza muestral

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

Divisor $n-1$: corrección de Bessel (estimador insesgado).

Desvío estándar (DE)

$$s = \sqrt{s^2}$$

Tiene las **mismas unidades** que la variable original.

Sensibilidad

La varianza y el DE son muy sensibles a valores extremos.

Rango, RIC y CV

Rango (recorrido)

$R = x_{\text{máx}} - x_{\text{mín}}$ — Muy sensible a outliers.

Rango Intercuartílico (RIC / IQR)

$$\text{RIC} = Q_3 - Q_1$$

Contiene el 50 % central de los datos. **Robusto** frente a outliers.

Coeficiente de Variación (CV)

$$CV = \frac{s}{\bar{x}} \times 100\,\%$$

Medida adimensional. Permite comparar dispersiones entre variables con distintas unidades o escalas.

Comparación de medidas de dispersión

Medida	**Robusta**	**Unidades**	**Uso típico**
Rango	No	Originales	Exploración rápida
Varianza (s^2)	No	Cuadradas	Cálculos teóricos
Desvío estándar (s)	No	Originales	Informe general
RIC	Sí	Originales	Datos con outliers
CV	No	Adimensional	Comparación cruzada

Contenidos

1 Introducción

2 Medidas de posición central

3 Medidas de dispersión

4 Medidas de forma

5 Tablas de frecuencia

6 Resumen

Asimetría (Skewness)

Coeficiente de asimetría de Fisher (g_1)

$$g_1 = \frac{1}{n} \frac{\sum_{i=1}^{n} (x_i - \bar{x})^3}{s^3}$$

- $g_1 = 0$: distribución **simétrica**.
- $g_1 > 0$: cola a la **derecha** (asimetría positiva). $\bar{x} > Me > Mo$.
- $g_1 < 0$: cola a la **izquierda** (asimetría negativa). $\bar{x} < Me < Mo$.

Regla empírica

Si $|g_1| < 0{,}5$: aproximadamente simétrica. $|g_1| > 1$: marcadamente asimétrica.

Curtosis (Kurtosis)

Coeficiente de curtosis de Fisher (g_2)

$$g_2 = \frac{1}{n}\frac{\sum_{i=1}^{n}(x_i - \bar{x})^4}{s^4} - 3$$

(exceso de curtosis respecto a la distribución Normal)

- $g_2 = 0$: **Mesocúrtica** (similar a la Normal).
- $g_2 > 0$: **Leptocúrtica** — pico pronunciado, colas pesadas.
- $g_2 < 0$: **Platicúrtica** — pico aplanado, colas livianas.

Contenidos

1 Introducción

2 Medidas de posición central

3 Medidas de dispersión

4 Medidas de forma

5 Tablas de frecuencia

6 Resumen

Tabla de frecuencias para datos cualitativos

Categoría	**Frec. abs.** (n_i)	**Frec. rel.** (f_i)	**Frec. acum.** (F_i)
A	15	0.30	0.30
B	22	0.44	0.74
C	13	0.26	1.00
Total	50	1.00	—

- $f_i = n_i/n$: proporción de cada categoría.
- $F_i = \sum_{j \leq i} f_j$: frecuencia acumulada (para ordinales o cuantitativas).

Tabla de frecuencias para datos cuantitativos

Para variables continuas se agrupan en **clases** (intervalos):

- Número de clases recomendado: regla de Sturges $k = 1 + 3{,}322 \log_{10}(n)$.
- Amplitud de clase: $h = (x_{\text{máx}} - x_{\text{mín}})/k$.
- Marca de clase: $m_i = (L_i + L_{i+1})/2$.

Convención

Los intervalos son cerrados a izquierda y abiertos a derecha: $[L_i, L_{i+1})$, excepto el último que se cierra en ambos extremos.

Contenidos

1 Introducción

2 Medidas de posición central

3 Medidas de dispersión

4 Medidas de forma

5 Tablas de frecuencia

6 Resumen

Resumen de la clase

Medidas estudiadas

- **Posición**: media, mediana, moda, cuantiles.
- **Dispersión**: rango, varianza, DE, RIC, CV.
- **Forma**: asimetría (g_1), curtosis (g_2).

Próxima clase

Clase 9: Análisis de distribuciones — histogramas, boxplots, Q-Q plots y ajuste de distribuciones teóricas.