Regresión Lineal Simple

Conceptos y Estimación

Métodos de Análisis de Datos 1

Universidad Nacional del Sur

Unidad 3 - Clase 14

Contenidos

1. Introducción al Modelado
2. Modelo de Regresión Lineal Simple
3. Supuestos del Modelo
4. Estimación por Mínimos Cuadrados
5. Coeficiente de Determinación R^2
6. Implementación en Python
7. Implementación en R
8. Resumen

¿Qué es un modelo estadístico?

Definición

Un modelo estadístico es una representación matemática de un fenómeno del mundo real que usa datos observados.

Objetivos principales:

- **Descripción:** Entender cómo se relacionan las variables
- **Predicción:** Estimar valores futuros de una variable
- **Inferencia:** Determinar qué variables son importantes
- **Control:** Ajustar por factores confusores

Modelos de regresión

La **regresión** modela la relación entre:

- Variable **respuesta** Y (dependiente, outcome)
- Variable(s) **predictora(s)** X (independiente(s), explicativa(s))

Tipo	**Características**
Lineal simple	1 predictor, relación lineal
Lineal múltiple	≥ 2 predictores, relación lineal
Polinomial	1 predictor, relación no lineal
Logística	Variable respuesta binaria

Esta clase: Regresión lineal simple

Definición del modelo

Modelo de regresión lineal simple

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i, \quad i = 1, 2, \ldots, n$$

donde:

- Y_i: valor observado de la respuesta
- X_i: valor del predictor
- β_0: **intercepto** (ordenada al origen)
- β_1: **pendiente**
- ϵ_i: **error aleatorio**, $\epsilon_i \sim N(0, \sigma^2)$ independientes
- n: tamaño de la muestra

Interpretación gráfica

regresion_simple.png

Interpretación de los parámetros

Intercepto β_0

Valor esperado de Y cuando $X = 0$

Pendiente β_1

Cambio esperado en Y cuando X aumenta en 1 unidad

Ejemplo: Precio de casas vs metros cuadrados

$$Y = 50 + 1{,}2X$$

- $\beta_0 = 50$: precio base (50 mil \$)
- $\beta_1 = 1{,}2$: cada m^2 adicional suma 1.2 mil \$ (1200 \$)

Supuestos fundamentales

Para que la inferencia sea válida:

1. **Linealidad:** La relación entre X e Y es lineal
2. **Independencia:** Las observaciones son independientes
3. **Homocedasticidad:** Varianza constante de los errores

$$\text{Var}(\epsilon_i) = \sigma^2 \text{ para todo } i$$

4. **Normalidad:** Los errores siguen una distribución normal

$$\epsilon_i \sim N(0, \sigma^2)$$

Nota: Los veremos en detalle en la clase de diagnóstico

¿Qué pasa si se violan los supuestos?

- **Linealidad:** Predicciones sesgadas, bajo R^2
- **Independencia:** Errores estándar incorrectos (muy optimistas)
- **Homocedasticidad:** Errores estándar incorrectos, intervalos inválidos
- **Normalidad:** Tests e intervalos menos confiables (especialmente con n pequeño)

Importante

La próxima clase veremos cómo **diagnosticar** y **corregir** estas violaciones

Método de Mínimos Cuadrados Ordinarios (MCO)

Objetivo: Encontrar la recta que mejor se ajusta a los datos

Criterio: Minimizar la suma de los cuadrados de los residuos

$$\text{SCR} = \sum_{i=1}^{n}(Y_i - \hat{Y}_i)^2 = \sum_{i=1}^{n}(Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i)^2$$

donde $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$ es el valor predicho.

Fórmulas de MCO

Las estimaciones que minimizan SCR son:

Pendiente

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n}(X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^{n}(X_i - \bar{X})^2} = \frac{S_{XY}}{S_{XX}}$$

Intercepto

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

donde:

- $\bar{X}, \bar{Y}$: medias muestrales
- $S_{XY} = \sum(X_i - \bar{X})(Y_i - \bar{Y})$: suma de productos cruzados
- $S_{XX} = \sum(X_i - \bar{X})^2$: suma de cuadrados de X

Ejemplo numérico

Datos: Altura (X, cm) vs Peso (Y, kg) de 5 personas

X_i	Y_i	$X_i - \bar{X}$	$Y_i - \bar{Y}$	$(X_i - \bar{X})(Y_i - \bar{Y})$
160	55	-10	-10	100
165	60	-5	-5	25
170	65	0	0	0
175	70	5	5	25
180	75	10	10	100
$\bar{X} = 170$	$\bar{Y} = 65$			$S_{XY} = 250$

$$S_{XX} = 10^2 + 5^2 + 0^2 + 5^2 + 10^2 = 250$$

$$\hat{\beta}_1 = \frac{250}{250} = 1{,}0, \quad \hat{\beta}_0 = 65 - 1{,}0 \times 170 = -105$$

Modelo: $\hat{Y} = -105 + 1{,}0X$

Propiedades de MCO

Los estimadores por MCO tienen propiedades deseables:

- **Insesgados:** $E(\hat{\beta}_0) = \beta_0$, $E(\hat{\beta}_1) = \beta_1$
- **Consistentes:** Convergen al valor verdadero cuando $n \to \infty$
- **BLUE (Best Linear Unbiased Estimator):**
  - Tienen la menor varianza entre todos los estimadores lineales insesgados
  - Teorema de Gauss-Markov

Importante

Estas propiedades se cumplen **bajo los supuestos del modelo**

Descomposición de la variabilidad

La variabilidad total de Y se descompone en:

$$\underbrace{\sum_{i=1}^{n}(Y_i - \bar{Y})^2}_{\text{SCT (Total)}} = \underbrace{\sum_{i=1}^{n}(\hat{Y}_i - \bar{Y})^2}_{\text{SCE (Explicada)}} + \underbrace{\sum_{i=1}^{n}(Y_i - \hat{Y}_i)^2}_{\text{SCR (Residual)}}$$

- **SCT:** Variabilidad total de Y (sin modelo)
- **SCE:** Variabilidad explicada por el modelo
- **SCR:** Variabilidad no explicada (error)

Coeficiente de determinación R^2

Definición

$$R^2 = \frac{\text{SCE}}{\text{SCT}} = 1 - \frac{\text{SCR}}{\text{SCT}}$$

Interpretación: Proporción de variabilidad de Y explicada por X

Propiedades:

- $0 \leq R^2 \leq 1$
- $R^2 = 0$: el modelo no explica nada
- $R^2 = 1$: ajuste perfecto
- En regresión simple: $R^2 = r_{XY}^2$ (cuadrado de la correlación)

Advertencia

R^2 alto no implica causalidad ni garantiza que el modelo sea adecuado

Ejemplo de R^2

Continuando con el ejemplo altura-peso:

Modelo: $\hat{Y} = -105 + 1{,}0X$

Y_i	$\hat{Y}_i$	$(Y_i - \bar{Y})^2$	$(Y_i - \hat{Y}_i)^2$
55	55	100	0
60	60	25	0
65	65	0	0
70	70	25	0
75	75	100	0
		SCT = 250	SCR = 0

$R^2 = 1 - \frac{0}{250} = 1{,}0$ (ajuste perfecto!)

Regresión lineal con statsmodels

```python
import pandas as pd
import statsmodels.api as sm
from statsmodels.formula.api import ols

# Datos
data = pd.DataFrame({
    'altura': [160, 165, 170, 175, 180],
    'peso': [55, 60, 65, 70, 75]
})

# Ajustar modelo
modelo = ols('peso ~ altura', data=data).fit()

# Resumen completo
print(modelo.summary())

# Coeficientes
print(f"Intercepto: {modelo.params['Intercept']:.2f}")
print(f"Pendiente: {modelo.params['altura']:.4f}")
```

Visualización

```
import matplotlib.pyplot as plt

# Grafico de dispersion y recta ajustada
plt.figure(figsize=(8, 5))
plt.scatter(data['altura'], data['peso'],
            label='Datos', s=80, alpha=0.6)
plt.plot(data['altura'], modelo.fittedvalues,
         'r-', linewidth=2, label='Ajuste')
plt.xlabel('Altura (cm)')
plt.ylabel('Peso (kg)')
plt.title('Regresion Lineal Simple')
plt.legend()
plt.grid(True, alpha=0.3)
plt.show()
```

Predicción

```
# Predecir para nuevos valores
nuevos_datos = pd.DataFrame({'altura': [172, 178, 168]})

# Prediccion puntual
predicciones = modelo.predict(nuevos_datos)
print("Predicciones:", predicciones.values)

# Prediccion con intervalo de confianza
pred_intervalo = modelo.get_prediction(nuevos_datos)
intervalos = pred_intervalo.summary_frame(alpha=0.05)
print(intervalos)

# Columnas: mean, mean_se, mean_ci_lower, mean_ci_upper,
#           obs_ci_lower, obs_ci_upper
```

Regresión lineal en R

```r
# Datos
altura <- c(160, 165, 170, 175, 180)
peso <- c(55, 60, 65, 70, 75)
data <- data.frame(altura, peso)

# Ajustar modelo
modelo <- lm(peso ~ altura, data = data)

# Resumen
summary(modelo)

# Coeficientes
coef(modelo)

# R^2
summary(modelo)$r.squared
```

Visualización en R

```r
# Grafico basico
plot(data$altura, data$peso,
     xlab = "Altura (cm)", ylab = "Peso (kg)",
     main = "Regresion Lineal Simple",
     pch = 19, col = "blue")
abline(modelo, col = "red", lwd = 2)

# Con ggplot2
library(ggplot2)
ggplot(data, aes(x = altura, y = peso)) +
  geom_point(size = 3, alpha = 0.6) +
  geom_smooth(method = "lm", se = TRUE,
              color = "red", fill = "pink") +
  theme_minimal() +
  labs(title = "Regresion Lineal Simple")
```

Predicción en R

```r
# Nuevos datos
nuevos <- data.frame(altura = c(172, 178, 168))

# Prediccion puntual
predict(modelo, nuevos)

# Intervalo de confianza para la media
predict(modelo, nuevos, interval = "confidence")

# Intervalo de prediccion para nuevas observaciones
predict(modelo, nuevos, interval = "prediction")

# El intervalo de prediccion es siempre mas ancho
# que el de confianza
```

Resumen de la clase

Aprendimos:

- El modelo de regresión lineal simple: $Y = \beta_0 + \beta_1 X + \epsilon$
- Interpretación de intercepto y pendiente
- Los 4 supuestos fundamentales (L.I.H.N.)
- Estimación por mínimos cuadrados (MCO)
- Coeficiente de determinación R^2
- Implementación en Python (statsmodels) y R (lm)

Próxima clase:

- Inferencia sobre los coeficientes (tests e intervalos)
- Predicción (intervalos de confianza vs predicción)
- ANOVA del modelo de regresión