Regresión Lineal Simple

Inferencia y Predicción

Métodos de Análisis de Datos 1

Universidad Nacional del Sur

Unidad 3 - Clase 15

Contenidos

1. Repaso Clase Anterior
2. Distribución de los Estimadores
3. Tests de Hipótesis
4. Intervalos de Confianza
5. ANOVA del Modelo de Regresión
6. Predicción
7. Implementación en Python
8. Implementación en R
9. Resumen

Repaso: Modelo y estimación

Modelo de regresión lineal simple:

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i, \quad \epsilon_i \sim N(0, \sigma^2)$$

Estimadores por MCO:

$$\hat{\beta}_1 = \frac{S_{XY}}{S_{XX}}, \quad \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

Bondad de ajuste:

$$R^2 = 1 - \frac{\text{SCR}}{\text{SCT}}$$

Hoy: ¿Son significativos los coeficientes? ¿Cómo hacer predicciones con incertidumbre?

Propiedades de $\hat{\beta}_1$ y $\hat{\beta}_0$

Bajo los supuestos del modelo, los estimadores MCO siguen distribuciones normales:

Pendiente

$$\hat{\beta}_1 \sim N\left(\beta_1, \frac{\sigma^2}{S_{XX}}\right)$$

Intercepto

$$\hat{\beta}_0 \sim N\left(\beta_0, \sigma^2\left[\frac{1}{n} + \frac{\bar{X}^2}{S_{XX}}\right]\right)$$

Problema: σ^2 es desconocido $\Rightarrow$ lo estimamos con:

$$s^2 = \frac{\text{SCR}}{n-2} = \frac{\sum(Y_i - \hat{Y}_i)^2}{n-2}$$

Errores estándar

Los **errores estándar** miden la precisión de las estimaciones:

Error estándar de $\hat{\beta}_1$

$$\mathrm{SE}(\hat{\beta}_1) = \sqrt{\frac{s^2}{S_{XX}}} = \frac{s}{\sqrt{S_{XX}}}$$

Error estándar de $\hat{\beta}_0$

$$\mathrm{SE}(\hat{\beta}_0) = s\sqrt{\frac{1}{n} + \frac{\bar{X}^2}{S_{XX}}}$$

Nota: Cuanto mayor sea S_{XX} (mayor variabilidad en X), menor será el error estándar de $\hat{\beta}_1$

Test sobre la pendiente

La pregunta más importante: **¿Hay relación entre X e Y?**

Hipótesis

$$H_0 : \beta_1 = 0 \quad \text{vs} \quad H_1 : \beta_1 \neq 0$$

Estadístico de prueba:

$$t = \frac{\hat{\beta}_1 - 0}{\text{SE}(\hat{\beta}_1)} = \frac{\hat{\beta}_1}{s/\sqrt{S_{XX}}} \sim t_{n-2}$$

Regla de decisión: Al nivel α, rechazamos H_0 si:

$$|t| > t_{n-2,\alpha/2}$$

Valor-p: $P(|T| > |t|)$ donde $T \sim t_{n-2}$

Ejemplo: Test sobre pendiente

Datos: Horas de estudio (X) vs Calificación (Y) de 20 estudiantes

Modelo ajustado: $\hat{Y} = 40 + 5{,}2X$

- $\hat{\beta}_1 = 5{,}2$
- $\text{SE}(\hat{\beta}_1) = 1{,}3$
- $t = \frac{5{,}2}{1{,}3} = 4{,}0$

Con $n = 20$, $t_{18,0{,}025} = 2{,}101$

Como $|4{,}0| > 2{,}101 \Rightarrow$ **Rechazamos** H_0

Conclusión: Hay evidencia significativa ($\alpha = 0{,}05$) de que las horas de estudio afectan la calificación.

Test sobre el intercepto

Menos común, pero a veces relevante:

Hipótesis

$$H_0 : \beta_0 = 0 \quad \text{vs} \quad H_1 : \beta_0 \neq 0$$

Estadístico:

$$t = \frac{\hat{\beta}_0}{\text{SE}(\hat{\beta}_0)} \sim t_{n-2}$$

¿Cuándo es útil?

- Cuando tiene sentido que la línea pase por el origen
- Ejemplo: relación dosis-respuesta donde dosis 0 $\Rightarrow$ respuesta 0

Intervalo de confianza para β_1

Un intervalo de confianza del $(1-\alpha) \times 100\,\%$ para β_1 es:

IC para la pendiente

$$\hat{\beta}_1 \pm t_{n-2,\alpha/2} \cdot \mathrm{SE}(\hat{\beta}_1)$$

Interpretación: Con 95 % de confianza, el verdadero valor de β_1 está en este intervalo.

Relación con el test: Si el IC no contiene 0, rechazamos $H_0 : \beta_1 = 0$

Ejemplo: IC para pendiente

Continuando el ejemplo anterior:

- $\hat{\beta}_1 = 5{,}2$
- $\text{SE}(\hat{\beta}_1) = 1{,}3$
- $t_{18,0{,}025} = 2{,}101$

IC 95 %:

$$5{,}2 \pm 2{,}101 \times 1{,}3 = 5{,}2 \pm 2{,}7 = [2{,}5, 7{,}9]$$

Interpretación: Con 95 % de confianza, cada hora adicional de estudio aumenta la calificación entre 2.5 y 7.9 puntos.

Como el intervalo no contiene 0, confirmamos que $\beta_1 \neq 0$ (consistente con el test).

Intervalo de confianza para β_0

Análogamente:

IC para el intercepto

$$\hat{\beta}_0 \pm t_{n-2,\alpha/2} \cdot \mathrm{SE}(\hat{\beta}_0)$$

Nota: Los IC para β_0 suelen ser muy anchos si $\bar{X}$ está lejos de 0, porque implica **extrapolación**.

Tabla ANOVA para regresión

Otra forma de probar $H_0 : \beta_1 = 0$ es mediante ANOVA:

Fuente	**SC**	**gl**	**CM**	**F**	**p-valor**
Regresión	SCE	1	SCE/1	CM_E/CM_R	$P(F_{1,n-2} > F)$
Residual	SCR	$n-2$	$\text{SCR}/(n-2)$		
Total	SCT	$n-1$			

donde:

- SC = Suma de Cuadrados
- gl = grados de libertad
- CM = Cuadrado Medio = SC/gl
- $F = \frac{\text{CM}_E}{\text{CM}_R}$

Relación entre test t y test F

En regresión lineal simple:

Equivalencia

$$F = t^2$$

Ambos tests prueban $H_0 : \beta_1 = 0$ y dan la misma conclusión.

¿Cuándo usar cada uno?

- Test t: regresión simple, o para coeficientes individuales en regresión múltiple
- Test F: regresión múltiple (próxima clase), para probar si **al menos un** predictor es útil

Dos tipos de predicción

Dado un valor X_0, queremos estimar:

1. **La media de Y para $X = X_0$**

$$E(Y|X = X_0) = \beta_0 + \beta_1 X_0$$

$\Rightarrow$ **Intervalo de confianza**

2. **El valor de una nueva observación individual con $X = X_0$**

$$Y_{\text{nuevo}} = \beta_0 + \beta_1 X_0 + \epsilon_{\text{nuevo}}$$

$\Rightarrow$ **Intervalo de predicción**

Predicción puntual

Para cualquiera de los dos casos, la estimación puntual es la misma:

Predicción puntual

$$\hat{Y}_0 = \hat{\beta}_0 + \hat{\beta}_1 X_0$$

La diferencia está en la **incertidumbre** asociada a la predicción.

Intervalo de confianza para la media

IC $(1-\alpha)\times 100\,\%$ para $E(Y|X=X_0)$:

IC para la media

$$\hat{Y}_0 \pm t_{n-2,\alpha/2}\cdot s\sqrt{\frac{1}{n}+\frac{(X_0-\bar{X})^2}{S_{XX}}}$$

Interpretación: Estimamos la calificación **promedio** de todos los estudiantes que estudian X_0 horas.

Nota: El intervalo es más estrecho cerca de $\bar{X}$ y más ancho en los extremos.

Intervalo de predicción para nueva observación

IC $(1-\alpha) \times 100\,\%$ para Y_{nuevo}:

Intervalo de predicción

$$\hat{Y}_0 \pm t_{n-2,\alpha/2} \cdot s\sqrt{1 + \frac{1}{n} + \frac{(X_0 - \bar{X})^2}{S_{XX}}}$$

Interpretación: Estimamos la calificación de **un estudiante específico** que estudia X_0 horas.

Diferencia clave: El término adicional "1" dentro de la raíz representa la variabilidad individual ϵ.

Comparación de intervalos

intervalos_prediccion.png

Ejemplo numérico: Predicción

Modelo: Calificación $= 40 + 5{,}2\times$ Horas

- $n = 20$, $\bar{X} = 4$, $S_{XX} = 80$, $s = 8$
- Queremos predecir para $X_0 = 5$ horas

Predicción puntual: $\hat{Y}_0 = 40 + 5{,}2 \times 5 = 66$

IC 95 % para la media:

$$66 \pm 2{,}101 \times 8\sqrt{\frac{1}{20} + \frac{(5-4)^2}{80}} = 66 \pm 3{,}8 = [62{,}2, 69{,}8]$$

Intervalo de predicción 95 %:

$$66 \pm 2{,}101 \times 8\sqrt{1 + \frac{1}{20} + \frac{(5-4)^2}{80}} = 66 \pm 17{,}1 = [48{,}9, 83{,}1]$$

Inferencia en Python

```python
import statsmodels.api as sm
from statsmodels.formula.api import ols

# Ajustar modelo
modelo = ols('Y ~ X', data=data).fit()

# Resumen completo (incluye tests t, p-valores, IC)
print(modelo.summary())

# Extraer coeficientes e ICs
print(modelo.params)  # coeficientes
print(modelo.bse)     # errores estandar
print(modelo.tvalues) # estadisticos t
print(modelo.pvalues) # p-valores

# IC 95% para coeficientes
print(modelo.conf_int(alpha=0.05))
```

Tabla ANOVA en Python

```python
from statsmodels.stats.anova import anova_lm

# Tabla ANOVA
tabla_anova = anova_lm(modelo, typ=2)
print(tabla_anova)

# Output:
#            sum_sq     df          F    PR(>F)
# X         1234.5    1.0     16.00    0.0008
# Residual  1389.2   18.0        NaN       NaN

# F = 16.00, p-valor = 0.0008 < 0.05
# => Rechazamos H0: beta_1 = 0
```

Predicción en Python

```python
import pandas as pd

# Nuevos datos
nuevos = pd.DataFrame({'X': [3, 5, 7]})

# Prediccion puntual
pred = modelo.predict(nuevos)
print("Predicciones:", pred.values)

# Con intervalos
pred_obj = modelo.get_prediction(nuevos)
intervalos = pred_obj.summary_frame(alpha=0.05)
print(intervalos)

# Columnas:
# - mean: prediccion puntual
# - mean_ci_lower/upper: IC para la media
# - obs_ci_lower/upper: intervalo de prediccion
```

Inferencia en R

```r
# Ajustar modelo
modelo <- lm(Y ~ X, data = data)

# Resumen (incluye todo)
summary(modelo)

# Extraer componentes
coef(modelo)            # coeficientes
summary(modelo)$coef    # tabla completa con SE, t, p

# IC 95% para coeficientes
confint(modelo, level = 0.95)

# Tabla ANOVA
anova(modelo)
```

Predicción en R

```r
# Nuevos datos
nuevos <- data.frame(X = c(3, 5, 7))

# Prediccion puntual
predict(modelo, nuevos)

# IC para la media
predict(modelo, nuevos, interval = "confidence",
        level = 0.95)

# Intervalo de prediccion
predict(modelo, nuevos, interval = "prediction",
        level = 0.95)

# Output: data.frame con columnas fit, lwr, upr
```

Resumen de la clase

Aprendimos:

- Distribución de $\hat{\beta}_0$ y $\hat{\beta}_1$
- Tests de hipótesis: $H_0 : \beta_1 = 0$
- Intervalos de confianza para los coeficientes
- Tabla ANOVA y relación $F = t^2$
- Dos tipos de predicción:
  - IC para la media de Y
  - Intervalo de predicción para nueva observación
- Implementación completa en Python y R

Próxima clase: Diagnóstico del modelo (verificar supuestos, detectar problemas)