Diagnóstico del Modelo

Verificación de Supuestos

Métodos de Análisis de Datos 1

Universidad Nacional del Sur

Unidad 3 - Clase 16

Contenidos

1. Introducción
2. Gráficos de Residuos
3. Tests Formales
4. Implementación
5. Resumen

¿Por qué diagnosticar?

Ajustar un modelo es fácil, validarlo es crucial.

Supuestos (L.I.H.N.):

1. **L**inealidad: $E(Y|X) = \beta_0 + \beta_1 X$
2. **I**ndependencia: observaciones independientes
3. **H**omocedasticidad: varianza constante
4. **N**ormalidad: $\epsilon \sim N(0, \sigma^2)$

Si se violan:

- Predicciones sesgadas
- Errores estándar incorrectos
- Tests e intervalos inválidos

Los residuos

Residuo ordinario

$$e_i = Y_i - \hat{Y}_i$$

Residuo estandarizado

$$r_i = \frac{e_i}{s\sqrt{1 - h_i}}$$

donde h_i es el leverage y $s = \sqrt{\text{SCR}/(n-2)}$

Los residuos estandarizados tienen media 0 y varianza ≈ 1

Gráfico 1: Residuos vs Ajustados

Detecta: No linealidad y heterocedasticidad

Lo ideal: Patrón aleatorio sin estructura

Problemas:

- Patrón curvo $\Rightarrow$ relación no lineal
- Forma de embudo $\Rightarrow$ heterocedasticidad

Soluciones:

- Transformaciones (log, raíz cuadrada)
- Regresión polinomial
- Errores estándar robustos

Gráfico 2: Q-Q Plot

Detecta: Violación de normalidad

Lo ideal: Puntos sobre la diagonal

Desviaciones:

- Colas pesadas: puntos se alejan en extremos
- Asimetría: curvatura sistemática

Nota: La normalidad es menos crítica con n grande (Teorema Central del Límite)

Gráfico 3: Scale-Location

Detecta: Heterocedasticidad de forma más clara

Grafica $\sqrt{|r_i|}$ vs valores ajustados

Lo ideal: Banda horizontal con dispersión uniforme

Problema: Tendencia ascendente/descendente $\Rightarrow$ varianza no constante

Gráfico 4: Residuos vs Leverage

Detecta: Observaciones influyentes

Conceptos:

- **Leverage** h_i: qué tan lejos está X_i de $\bar{X}$

$$h_i = \frac{1}{n} + \frac{(X_i - \bar{X})^2}{S_{XX}}$$

- **Distancia de Cook** D_i: influencia total

$$D_i = \frac{r_i^2}{p+1} \cdot \frac{h_i}{1 - h_i}$$

Regla: $D_i > 1 \Rightarrow$ observación muy influyente

Test de normalidad

Shapiro-Wilk:

$$H_0 : \text{residuos normales} \quad \text{vs} \quad H_1 : \text{no normales}$$

Nota: Con n grande, muy sensible. Siempre complementar con Q-Q plot.

Test de homocedasticidad

Breusch-Pagan:

$$H_0 : \text{Var}(\epsilon) = \sigma^2 \quad \text{vs} \quad H_1 : \text{varianza no constante}$$

Test de White: Versión más robusta

Test de independencia

Durbin-Watson: Para series temporales

$$DW = \frac{\sum_{i=2}^{n}(e_i - e_{i-1})^2}{\sum_{i=1}^{n} e_i^2}$$

- $DW \approx 2$: no autocorrelación
- $DW < 2$: autocorrelación positiva
- $DW > 2$: autocorrelación negativa

Python: Gráficos

```
import matplotlib.pyplot as plt
import scipy.stats as stats

fig, axes = plt.subplots(2, 2, figsize=(12, 10))

# 1. Residuos vs Ajustados
axes[0,0].scatter(modelo.fittedvalues, modelo.resid)
axes[0,0].axhline(0, color='red', linestyle='--')
axes[0,0].set_title('Residuos vs Ajustados')

# 2. Q-Q Plot
stats.probplot(modelo.resid, dist="norm",
               plot=axes[0,1])

# 3. Scale-Location
axes[1,0].scatter(modelo.fittedvalues,
                  np.sqrt(np.abs(modelo.resid_pearson)))

# 4. Residuos vs Leverage
```

Python: Tests

```python
from scipy import stats
from statsmodels.stats.diagnostic import het_breuschpagan
from statsmodels.stats.stattools import durbin_watson

# Shapiro-Wilk
stat, p = stats.shapiro(modelo.resid)
print(f"Shapiro-Wilk p-valor: {p:.4f}")

# Breusch-Pagan
bp = het_breuschpagan(modelo.resid, modelo.model.exog)
print(f"Breusch-Pagan p-valor: {bp[1]:.4f}")

# Durbin-Watson
dw = durbin_watson(modelo.resid)
print(f"Durbin-Watson: {dw:.4f}")

# Cook's distance
cooks = influence.cooks_distance[0]
print(f"Obs influyentes: {np.where(cooks > 1)[0]}")
```

R: Todo en uno

```r
# Graficos automaticos
par(mfrow = c(2, 2))
plot(modelo)
par(mfrow = c(1, 1))

# Tests
shapiro.test(modelo$residuals)

library(lmtest)
bptest(modelo)
dwtest(modelo)

# Cook's distance
cooks <- cooks.distance(modelo)
plot(cooks, type="h")
abline(h=1, col="red", lty=2)
```

Resumen

4 gráficos clave:

1. Residuos vs Ajustados (linealidad, homocedasticidad)
2. Q-Q Plot (normalidad)
3. Scale-Location (homocedasticidad)
4. Residuos vs Leverage (influencia)

Tests: Shapiro-Wilk, Breusch-Pagan, Durbin-Watson

Medidas: Leverage, Distancia de Cook

Próxima clase: Regresión lineal múltiple