Regresión Lineal Múltiple

Múltiples Predictores

Métodos de Análisis de Datos 1

Universidad Nacional del Sur

Unidad 3 - Clase 17

Contenidos

1. Del modelo simple al múltiple
2. Interpretación
3. Bondad de ajuste
4. Inferencia
5. Multicolinealidad
6. Implementación
7. Resumen

Motivación

En la práctica, la respuesta depende de **múltiples** factores.

Ejemplos:

- Precio de casa: metros cuadrados, habitaciones, antigüedad, ubicación
- Rendimiento académico: horas de estudio, asistencia, nivel previo
- Ventas: publicidad TV, radio, web, estacionalidad

Ventajas del modelo múltiple:

1. Predicciones más precisas
2. Controla confusores (variables que afectan tanto X como Y)
3. Permite estudiar efecto de cada variable ajustando por las demás

Modelo de regresión lineal múltiple

Con p predictores:

Modelo

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \cdots + \beta_p X_{ip} + \epsilon_i$$

donde:

- Y_i: variable respuesta
- X_{ij}: j-ésimo predictor para observación i
- β_0: intercepto
- β_j: coeficiente del j-ésimo predictor
- $\epsilon_i \sim N(0, \sigma^2)$: errores independientes

Forma matricial

Notación matricial

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$$

$$\begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix} = \begin{bmatrix} 1 & X_{11} & X_{12} & \cdots & X_{1p} \\ 1 & X_{21} & X_{22} & \cdots & X_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & X_{n1} & X_{n2} & \cdots & X_{np} \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{bmatrix} + \begin{bmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{bmatrix}$$

Dimensiones: $\mathbf{Y}$ es $n \times 1$, $\mathbf{X}$ es $n \times (p+1)$, $\boldsymbol{\beta}$ es $(p+1) \times 1$

Estimación por MCO

Estimador MCO

$$\hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$$

Propiedades: Mismas que en regresión simple

- Insesgado
- BLUE (mínima varianza entre estimadores lineales insesgados)
- Consistente

Nota: En la práctica, Python y R hacen estos cálculos automáticamente

Interpretación de coeficientes

Diferencia clave con regresión simple:

Interpretación en modelo múltiple

β_j es el cambio esperado en Y cuando X_j aumenta en 1 unidad, **manteniendo constantes** las demás variables.

Ejemplo: Precio de casas

$$\text{Precio} = 50 + 1{,}2 \times \text{m}^2 + 5 \times \text{habitaciones} - 0{,}8 \times \text{antigüedad}$$

- $\beta_1 = 1{,}2$: Por cada m^2 adicional, el precio aumenta 1.2 mil \$, **para igual número de habitaciones y antigüedad**
- $\beta_2 = 5$: Cada habitación adicional suma 5 mil \$, **para igual tamaño y antigüedad**
- $\beta_3 = -0{,}8$: Cada año adicional reduce 0.8 mil \$, **para igual tamaño y habitaciones**

Cuidado con la interpretación

Importante

Los coeficientes solo tienen sentido si los predictores pueden variar independientemente.

Problema: Si hay correlación entre predictores (multicolinealidad), la interpretación se complica.

Ejemplo: Altura y peso están correlacionados

- Modelo: IMC $\sim$ altura $+$ peso
- ¿Tiene sentido "mantener peso constante y variar altura¿
- Los coeficientes individuales pueden ser engañosos

R^2 y R^2 ajustado

R^2 **estándar:**

$$R^2 = 1 - \frac{\text{SCR}}{\text{SCT}}$$

Problema: R^2 siempre aumenta al agregar variables, aunque sean irrelevantes

R^2 ajustado

$$R^2_{\text{adj}} = 1 - \frac{\text{SCR}/(n-p-1)}{\text{SCT}/(n-1)} = 1 - (1 - R^2)\frac{n-1}{n-p-1}$$

Ventaja: Penaliza la complejidad. Puede disminuir si se agregan variables irrelevantes.

Uso: Comparar modelos con distinto número de predictores

Test F global

¿Es útil el modelo completo?

Hipótesis

$$H_0 : \beta_1 = \beta_2 = \cdots = \beta_p = 0 \quad \text{vs} \quad H_1 : \text{al menos un } \beta_j \neq 0$$

Estadístico:

$$F = \frac{\text{SCE}/p}{\text{SCR}/(n-p-1)} \sim F_{p,n-p-1}$$

Si p-valor $< \alpha \Rightarrow$ rechazamos H_0 (al menos una variable es útil)

Tests t individuales

Para cada coeficiente:

Hipótesis

$$H_0 : \beta_j = 0 \quad \text{vs} \quad H_1 : \beta_j \neq 0$$

Estadístico:

$$t_j = \frac{\hat{\beta}_j}{\text{SE}(\hat{\beta}_j)} \sim t_{n-p-1}$$

Interpretación: X_j es significativo **dado que** las demás variables ya están en el modelo.

Cuidado: Puede ser que F sea significativo pero ningún t_j lo sea (multicolinealidad)

¿Qué es la multicolinealidad?

Definición

Correlación alta entre dos o más predictores

Consecuencias:

- Coeficientes inestables (alta varianza)
- Errores estándar grandes
- Tests t no significativos, pero test F sí
- Interpretación difícil
- Predicciones siguen siendo válidas

No afecta: R^2, predicciones dentro del rango de los datos

Detección: VIF

Factor de Inflación de la Varianza

$$\text{VIF}_j = \frac{1}{1 - R_j^2}$$

donde R_j^2 es el R^2 de la regresión de X_j sobre las demás variables.

Interpretación:

- $\text{VIF}_j = 1$: X_j no correlacionado con otras variables
- $\text{VIF}_j > 5$: multicolinealidad moderada
- $\text{VIF}_j > 10$: multicolinealidad severa

Soluciones a la multicolinealidad

Opciones:

1. **Eliminar variables redundantes**
   - Quitar variables muy correlacionadas
2. **Combinar variables**
   - Crear índices o promedios
3. **Aumentar tamaño muestral**
   - Más datos reducen varianza de $\hat{\beta}$
4. **Regularización**
   - Ridge, Lasso (veremos en clases futuras)
5. **PCA (Análisis de Componentes Principales)**
   - Crear predictores no correlacionados

Python: Modelo múltiple

```python
from statsmodels.formula.api import ols

# Multiples predictores con formula
modelo = ols('precio ~ metros + habitaciones + antiguedad',
             data=casas).fit()

print(modelo.summary())

# O con matriz de dise o manual
from sklearn.linear_model import LinearRegression
X = casas[['metros', 'habitaciones', 'antiguedad']]
y = casas['precio']
modelo_sk = LinearRegression().fit(X, y)
print(f"Coeficientes: {modelo_sk.coef_}")
print(f"Intercepto: {modelo_sk.intercept_}")
print(f"R^2: {modelo_sk.score(X, y):.4f}")
```

Python: VIF

```python
from statsmodels.stats.outliers_influence import variance_inflation_factor

# Calcular VIF para cada variable
X = casas[['metros', 'habitaciones', 'antiguedad']]
vif_data = pd.DataFrame()
vif_data["Variable"] = X.columns
vif_data["VIF"] = [variance_inflation_factor(X.values, i)
                   for i in range(X.shape[1])]
print(vif_data)

#     Variable    VIF
# 0      metros   2.3
# 1 habitaciones  8.5
# 2  antiguedad   1.8
```

R: Modelo múltiple

```r
# Ajustar modelo
modelo <- lm(precio ~ metros + habitaciones + antiguedad,
             data = casas)

summary(modelo)

# VIF
library(car)
vif(modelo)

# Comparar modelos
modelo1 <- lm(precio ~ metros, data = casas)
modelo2 <- lm(precio ~ metros + habitaciones, data = casas)
modelo3 <- lm(precio ~ metros + habitaciones + antiguedad,
              data = casas)

anova(modelo1, modelo2, modelo3)
```

Resumen

Aprendimos:

- Modelo de regresión múltiple: $Y = \beta_0 + \sum \beta_j X_j + \epsilon$
- Interpretación: efecto de X_j manteniendo constantes las demás
- R^2 ajustado para comparar modelos
- Test F global y tests t individuales
- Multicolinealidad: detección (VIF) y soluciones
- Implementación en Python y R

Próxima clase: Selección de variables y regresión polinomial