Selección de Variables y Regresión Polinomial

Elegir el mejor modelo

Métodos de Análisis de Datos 1

Universidad Nacional del Sur

Unidad 3 - Clase 18

Contenidos

1. Selección de Variables
2. Regresión Polinomial
3. Implementación
4. Resumen

¿Por qué seleccionar variables?

Con muchas variables candidatas, ¿cuáles incluir?

Tensión:

- Más variables $\Rightarrow$ mejor ajuste (R^2 más alto)
- Pero: sobreajuste, interpretación difícil, multicolinealidad

Ventajas de modelos simples:

1. Más interpretables
2. Mejor generalización (menor sobreajuste)
3. Menor costo computacional
4. Predicciones más estables

Objetivo: Encontrar el modelo más simple que explique bien los datos

Criterios de selección

AIC (Criterio de Información de Akaike):

$$\text{AIC} = n \ln\left(\frac{\text{SCR}}{n}\right) + 2(p+1)$$

BIC (Criterio Bayesiano):

$$\text{BIC} = n \ln\left(\frac{\text{SCR}}{n}\right) + \ln(n)(p+1)$$

Interpretación: Menor es mejor

Diferencia: BIC penaliza más la complejidad que AIC

- AIC $\Rightarrow$ modelos más complejos
- BIC $\Rightarrow$ modelos más simples (preferido para n grande)

Métodos de búsqueda

1. **Best Subset (mejor subconjunto):**
   - Probar todos los modelos posibles: 2^p
   - Elegir el de menor AIC/BIC
   - Computacionalmente costoso para $p > 15$
2. **Forward (hacia adelante):**
   - Empezar con modelo vacío
   - Agregar la variable que más mejora el criterio
   - Repetir hasta que ninguna mejore
3. **Backward (hacia atrás):**
   - Empezar con modelo completo
   - Eliminar la variable menos significativa
   - Repetir hasta que todas sean significativas

Método Stepwise

Stepwise (por pasos): Combina forward y backward

Algoritmo:

1. Empezar con modelo vacío (o completo)
2. En cada paso:
   - Considerar agregar una variable (forward)
   - Considerar eliminar una variable (backward)
3. Elegir la acción que más mejora el criterio
4. Repetir hasta convergencia

Advertencia

Los métodos automáticos son heurísticos. No garantizan encontrar el mejor modelo. Siempre combinar con conocimiento del dominio.

Validación cruzada

Problema: AIC/BIC se calculan en los mismos datos usados para ajustar

Solución: Validación cruzada

K-fold CV:

1. Dividir datos en K partes (folds)
2. Para cada fold:
   - Ajustar modelo en $K - 1$ folds
   - Predecir en el fold restante
   - Calcular error
3. Error CV = promedio de los K errores

Común: $K = 5$ o $K = 10$

Ventaja: Estima error de predicción en datos nuevos

¿Cuándo usar polinomios?

Cuando la relación entre X e Y no es lineal.

Modelo polinomial de grado d:

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \cdots + \beta_d X^d + \epsilon$$

Nota importante: Aunque la relación con X no es lineal, el modelo es **lineal en los parámetros** β_j. Por lo tanto:

- Se puede usar MCO
- Todas las técnicas de regresión múltiple aplican

Implementación: Crear variables $X_2 = X^2$, $X_3 = X^3$, etc., y ajustar regresión múltiple estándar.

Grados comunes

Grado 2 (cuadrática):

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \epsilon$$

- Forma de U o U invertida
- Un punto de inflexión

Grado 3 (cúbica):

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \beta_3 X^3 + \epsilon$$

- Forma de S
- Dos puntos de inflexión

Cuidado

Grados muy altos ($d > 4$) tienden a sobreajustar

Selección del grado

¿Qué grado d elegir?

Métodos:

1. **Visualización:** Graficar ajustes para distintos d
2. **AIC/BIC:** Elegir d con menor AIC/BIC
3. **Validación cruzada:** Elegir d con menor error CV
4. **Test F jerárquico:** Comparar modelos anidados

Recomendación: Empezar simple ($d = 2$) y aumentar solo si es necesario

Interpretación de polinomios

Problema: Los coeficientes individuales son difíciles de interpretar

Ejemplo: $\hat{Y} = 10 + 3X - 0{,}5X^2$

- $\beta_1 = 3$ no significa "por cada unidad de X, Y aumenta 3"
- El efecto de X depende del valor de X (por el término X^2)

Mejor enfoque:

- Graficar la curva ajustada
- Calcular efectos marginales para valores específicos de X
- Identificar máximos/mínimos

Máximos y mínimos

Para una cuadrática $Y = \beta_0 + \beta_1 X + \beta_2 X^2$:

Punto crítico:

$$\frac{dY}{dX} = \beta_1 + 2\beta_2 X = 0 \quad \Rightarrow \quad X^* = -\frac{\beta_1}{2\beta_2}$$

- Si $\beta_2 < 0 \Rightarrow X^*$ es un máximo
- Si $\beta_2 > 0 \Rightarrow X^*$ es un mínimo

Ejemplo: $\hat{Y} = 10 + 3X - 0{,}5X^2$

$$X^* = -\frac{3}{2(-0{,}5)} = 3$$

El precio máximo se alcanza en $X = 3$

Python: Selección stepwise

```python
import statsmodels.api as sm

# No hay stepwise nativo, pero se puede hacer manual
# O usar libreria mlxtend
from mlxtend.feature_selection import SequentialFeatureSelector as SFS
from sklearn.linear_model import LinearRegression

# Forward selection
sfs = SFS(LinearRegression(),
          k_features='best',
          forward=True,
          scoring='neg_mean_squared_error',
          cv=5)

sfs.fit(X, y)
print(f"Variables seleccionadas: {sfs.k_feature_names_}")

# O calcular AIC/BIC manualmente
print(f"AIC: {modelo.aic:.2f}")
```

Python: Regresión polinomial

```python
import numpy as np
from sklearn.preprocessing import PolynomialFeatures

# Crear features polinomiales
poly = PolynomialFeatures(degree=2, include_bias=False)
X_poly = poly.fit_transform(X)

# Ajustar modelo
modelo = LinearRegression().fit(X_poly, y)

# O con statsmodels y formula
from statsmodels.formula.api import ols
modelo = ols('Y ~ X + I(X**2)', data=data).fit()

# Para grado 3
modelo = ols('Y ~ X + I(X**2) + I(X**3)', data=data).fit()
```

R: Selección stepwise

```r
# Modelo completo
modelo_completo <- lm(Y ~ ., data = datos)

# Stepwise (ambas direcciones)
modelo_step <- step(modelo_completo, direction = "both")

# Forward
modelo_forward <- step(lm(Y ~ 1, data = datos),
                       scope = list(lower = ~1,
                                    upper = modelo_completo),
                       direction = "forward")

# Backward
modelo_backward <- step(modelo_completo,
                        direction = "backward")

# Ver criterios
AIC(modelo_step)
BIC(modelo_step)
```

R: Regresión polinomial

```r
# Grado 2
modelo_poly2 <- lm(Y ~ X + I(X^2), data = datos)

# Grado 3
modelo_poly3 <- lm(Y ~ X + I(X^2) + I(X^3), data = datos)

# O usar poly() que crea polinomios ortogonales
modelo_ortho <- lm(Y ~ poly(X, degree = 3), data = datos)

# Graficar
x_seq <- seq(min(datos$X), max(datos$X), length.out = 100)
y_pred <- predict(modelo_poly2,
                  newdata = data.frame(X = x_seq))

plot(datos$X, datos$Y)
lines(x_seq, y_pred, col = "red", lwd = 2)
```

Resumen

Selección de variables:

- Criterios: AIC, BIC, validación cruzada
- Métodos: best subset, forward, backward, stepwise
- Siempre combinar con conocimiento del dominio

Regresión polinomial:

- Para relaciones no lineales
- Crear variables $X^2, X^3, \ldots$
- Elegir grado con AIC/BIC/CV
- Cuidado con sobreajuste (grados altos)

Próxima clase: Correlación y ANCOVA