Unidad 3: Modelado Estadístico

Regresión y Correlación

Métodos de Análisis de Datos 1
Universidad Nacional del Sur

Primer Semestre 2026

Contents

1 Introducción al Modelado Estadístico

El modelado estadístico es el proceso de construir representaciones matemáticas de fenómenos del mundo real utilizando datos observados. En esta unidad nos centraremos en modelos de **regresión**, que permiten estudiar y cuantificar relaciones entre variables.

1.1 ¿Qué es un modelo de regresión?

Un modelo de regresión describe cómo una variable respuesta Y (también llamada variable dependiente) se relaciona con una o más variables predictoras $X_1, X_2, \ldots, X_p$ (variables independientes o explicativas).

Objetivos principales:

- **Descripción:** Entender cómo se relacionan las variables
- **Predicción:** Estimar valores de Y para nuevos valores de X
- **Inferencia:** Determinar qué variables son importantes y cuantificar su efecto
- **Control:** Ajustar por variables confusoras en estudios observacionales

1.2 Tipos de modelos de regresión

Tipo	**Características**
Regresión lineal simple	1 predictor, relación lineal
Regresión lineal múltiple	≥ 2 predictores, relación lineal
Regresión polinomial	1 predictor, relación no lineal
Regresión no paramétrica	Relaciones complejas sin forma funcional
Regresión logística	Variable respuesta binaria
Regresión de Poisson	Variable respuesta de conteo

En esta unidad nos concentraremos en modelos de **regresión lineal**.

2 Regresión Lineal Simple

2.1 Definición del modelo

La regresión lineal simple modela la relación entre una variable respuesta Y y un predictor X mediante una línea recta:

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i, \quad i = 1, 2, \ldots, n \tag{1}$$

donde:

- Y_i: valor observado de la variable respuesta para la observación i
- X_i: valor del predictor para la observación i
- β_0: ordenada al origen (intercepto)
- β_1: pendiente (cambio en Y por unidad de cambio en X)
- ϵ_i: error aleatorio, $\epsilon_i \sim N(0, \sigma^2)$ independientes
- n: tamaño de la muestra

2.2 Supuestos del modelo

Para que la inferencia sea válida, se asumen:

1. **Linealidad:** La relación entre X e Y es lineal
2. **Independencia:** Las observaciones son independientes entre sí
3. **Homocedasticidad:** La varianza de los errores es constante: $\text{Var}(\epsilon_i) = \sigma^2$ para todo i
4. **Normalidad:** Los errores siguen una distribución normal: $\epsilon_i \sim N(0, \sigma^2)$
5. **No multicolinealidad:** (más relevante en regresión múltiple)

2.3 Estimación de parámetros: Mínimos Cuadrados Ordinarios (MCO)

El método de **mínimos cuadrados ordinarios** (MCO, o OLS en inglés) estima β_0 y β_1 minimizando la suma de los cuadrados de los residuos:

$$\text{SCR} = \sum_{i=1}^{n}(Y_i - \hat{Y}_i)^2 = \sum_{i=1}^{n}(Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i)^2 \tag{2}$$

Las estimaciones por MCO son:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n}(X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^{n}(X_i - \bar{X})^2} = \frac{S_{XY}}{S_{XX}} \tag{3}$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X} \tag{4}$$

donde $\bar{X}$ y $\bar{Y}$ son las medias muestrales de X e Y.

2.4 Interpretación de los coeficientes

- **Intercepto** $\hat{\beta}_0$: Valor esperado de Y cuando $X = 0$
- **Pendiente** $\hat{\beta}_1$: Cambio esperado en Y cuando X aumenta en 1 unidad

Ejemplo: Si modelamos el precio de casas (Y, en miles de \$) en función de los metros cuadrados (X) y obtenemos:

$$\hat{Y} = 50 + 1.2X$$

entonces:

- $\hat{\beta}_0 = 50$: Una casa de 0 m^2 tendría un precio base de 50 mil \$ (interpretación sin sentido práctico en este caso)
- $\hat{\beta}_1 = 1.2$: Cada m^2 adicional aumenta el precio esperado en 1.2 mil \$ (1200 \$)

2.5 Coeficiente de determinación R^2

El R^2 mide la proporción de variabilidad de Y explicada por el modelo:

$$R^2 = \frac{\text{SCE}}{\text{SCT}} = 1 - \frac{\text{SCR}}{\text{SCT}} \tag{5}$$

donde:

- $\text{SCT} = \sum_{i=1}^{n}(Y_i - \bar{Y})^2$: suma de cuadrados total

- $\text{SCE} = \sum_{i=1}^{n}(\hat{Y}_i - \bar{Y})^2$: suma de cuadrados explicada (por el modelo)
- $\text{SCR} = \sum_{i=1}^{n}(Y_i - \hat{Y}_i)^2$: suma de cuadrados residual

Propiedades:

- $0 \leq R^2 \leq 1$
- $R^2 = 0$: el modelo no explica nada (X no ayuda a predecir Y)
- $R^2 = 1$: ajuste perfecto (todos los puntos sobre la recta)
- En regresión lineal simple: $R^2 = r_{XY}^2$ (cuadrado de la correlación de Pearson)

Advertencia: Un R^2 alto no implica causalidad ni garantiza que el modelo sea adecuado.

2.6 Inferencia sobre los coeficientes

Bajo los supuestos del modelo, los estimadores $\hat{\beta}_0$ y $\hat{\beta}_1$ siguen distribuciones normales:

$$\hat{\beta}_1 \sim N\left(\beta_1, \frac{\sigma^2}{S_{XX}}\right) \tag{6}$$

$$\hat{\beta}_0 \sim N\left(\beta_0, \sigma^2\left[\frac{1}{n} + \frac{\bar{X}^2}{S_{XX}}\right]\right) \tag{7}$$

En la práctica, σ^2 se estima con:

$$s^2 = \frac{\text{SCR}}{n-2} \tag{8}$$

Test de hipótesis: Para probar $H_0 : \beta_1 = 0$ vs $H_1 : \beta_1 \neq 0$:

$$t = \frac{\hat{\beta}_1}{\text{SE}(\hat{\beta}_1)} \sim t_{n-2} \tag{9}$$

donde $\text{SE}(\hat{\beta}_1) = \sqrt{s^2/S_{XX}}$.
Si $|t| > t_{n-2,\alpha/2}$, rechazamos H_0 al nivel α.
Intervalos de confianza:

$$\text{IC}_{1-\alpha}(\beta_1) = \hat{\beta}_1 \pm t_{n-2,\alpha/2} \cdot \text{SE}(\hat{\beta}_1) \tag{10}$$

2.7 Predicción

Dado un nuevo valor X_0, podemos calcular:

1. **Predicción puntual:**

$$\hat{Y}_0 = \hat{\beta}_0 + \hat{\beta}_1 X_0 \tag{11}$$

2. **Intervalo de confianza para la media** $E(Y|X = X_0)$:

$$\hat{Y}_0 \pm t_{n-2,\alpha/2} \cdot s\sqrt{\frac{1}{n} + \frac{(X_0 - \bar{X})^2}{S_{XX}}} \tag{12}$$

3. **Intervalo de predicción para una nueva observación:**

$$\hat{Y}_0 \pm t_{n-2,\alpha/2} \cdot s\sqrt{1 + \frac{1}{n} + \frac{(X_0 - \bar{X})^2}{S_{XX}}} \tag{13}$$

El intervalo de predicción es siempre más ancho que el de confianza porque incluye tanto la incertidumbre del modelo como la variabilidad individual.

3 Diagnóstico del Modelo

3.1 Análisis de residuos

Los **residuos** son las diferencias entre valores observados y predichos:

$$e_i = Y_i - \hat{Y}_i \tag{14}$$

Examinamos los residuos para verificar los supuestos del modelo.

3.1.1 Gráficos de diagnóstico principales

1. Residuos vs Valores Ajustados:

- **Qué buscar:** Patrón aleatorio sin estructura
- **Problemas detectables:** No linealidad, heterocedasticidad
- Si hay patrón en forma de embudo ⇒ heterocedasticidad
- Si hay curvatura ⇒ relación no lineal

2. Q-Q Plot (Normal):

- **Qué buscar:** Puntos sobre la diagonal
- **Problemas detectables:** Violación de normalidad

3. Scale-Location (Raíz de residuos estandarizados vs valores ajustados):

- **Qué buscar:** Banda horizontal con dispersión uniforme
- **Problemas detectables:** Heterocedasticidad

4. Residuos vs Leverage (Distancia de Cook):

- **Qué buscar:** Identificar observaciones influyentes
- **Problemas detectables:** Outliers con alta influencia

3.2 Tests formales

Test de normalidad:

- Shapiro-Wilk: H_0: los residuos siguen una distribución normal

Test de homocedasticidad:

- Breusch-Pagan: H_0: varianza constante
- White: versión más robusta

3.3 Medidas de influencia

Leverage (apalancamiento): Mide qué tan lejos está X_i del promedio $\bar{X}$

$$h_i = \frac{1}{n} + \frac{(X_i - \bar{X})^2}{S_{XX}} \tag{15}$$

Distancia de Cook: Combina residuo y leverage para medir influencia

$$D_i = \frac{(e_i)^2}{2s^2} \cdot \frac{h_i}{1 - h_i} \tag{16}$$

Observaciones con $D_i > 1$ son influyentes y deben ser examinadas cuidadosamente.

4 Regresión Lineal Múltiple

4.1 Modelo con múltiples predictores

La regresión lineal múltiple extiende el modelo simple a p predictores:

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \cdots + \beta_p X_{ip} + \epsilon_i \tag{17}$$

En forma matricial:

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon} \tag{18}$$

donde:

- $\mathbf{Y}$: vector de respuestas $(n \times 1)$
- $\mathbf{X}$: matriz de diseño $(n \times (p+1))$, incluye columna de 1's para el intercepto
- $\boldsymbol{\beta}$: vector de coeficientes $((p+1) \times 1)$
- $\boldsymbol{\epsilon}$: vector de errores $(n \times 1)$

4.2 Estimación por MCO

El estimador de MCO en forma matricial:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y} \tag{19}$$

Supuestos: Los mismos que en regresión simple, más:

- **No multicolinealidad:** Las variables predictoras no están perfectamente correlacionadas entre sí

4.3 Interpretación de coeficientes

En regresión múltiple, cada β_j se interpreta como el cambio esperado en Y cuando X_j aumenta en 1 unidad, **manteniendo constantes** las demás variables.

Ejemplo:

$$\hat{Y} = 50 + 1.2X_1 + 0.8X_2$$

donde Y = precio de casa (miles \$), X_1 = m^2, X_2 = número de habitaciones.

- $\hat{\beta}_1 = 1.2$: Por cada m^2 adicional, el precio aumenta 1.2 mil \$, **para un número fijo de habitaciones**
- $\hat{\beta}_2 = 0.8$: Por cada habitación adicional, el precio aumenta 0.8 mil \$, **para un tamaño fijo**

4.4 R^2 ajustado

El R^2 siempre aumenta al agregar variables, aunque no aporten información. El R^2 **ajustado** penaliza la complejidad:

$$R^2_{\text{adj}} = 1 - \frac{\text{SCR}/(n-p-1)}{\text{SCT}/(n-1)} = 1 - (1 - R^2)\frac{n-1}{n-p-1} \tag{20}$$

R^2_{adj} puede disminuir si se agrega una variable irrelevante.

4.5 Test F global

Para probar si **al menos una** variable es útil:

$$H_0 : \beta_1 = \beta_2 = \cdots = \beta_p = 0 \quad \text{vs} \quad H_1 : \text{al menos un } \beta_j \neq 0$$

Estadístico:

$$F = \frac{\text{SCE}/p}{\text{SCR}/(n-p-1)} \sim F_{p,n-p-1} \tag{21}$$

Si $F > F_{p,n-p-1,\alpha}$, rechazamos H_0.

4.6 Tests t individuales

Para cada coeficiente β_j:

$$H_0 : \beta_j = 0 \quad \text{vs} \quad H_1 : \beta_j \neq 0$$

$$t_j = \frac{\hat{\beta}_j}{\text{SE}(\hat{\beta}_j)} \sim t_{n-p-1} \tag{22}$$

Importante: Un test t significativo indica que X_j aporta información **dado que las demás variables ya están en el modelo**.

4.7 Multicolinealidad

Definición: Ocurre cuando dos o más predictores están altamente correlacionados.

Consecuencias:

- Estimaciones de β_j inestables (alta varianza)
- Interpretación de coeficientes difícil
- Tests t individuales no significativos, pero test F sí

Detección:

- **VIF (Factor de Inflación de la Varianza):**

$$\text{VIF}_j = \frac{1}{1 - R_j^2}$$

  donde R_j^2 es el R^2 de la regresión de X_j sobre las demás variables.

  Regla práctica: VIF > 10 indica multicolinealidad problemática

Soluciones:

- Eliminar variables redundantes
- Combinar variables correlacionadas
- Usar regresión ridge o lasso (regularización)
- Análisis de componentes principales

5 Selección de Variables

5.1 ¿Por qué seleccionar variables?

Ventajas de modelos más simples:

- Más interpretables
- Menor riesgo de sobreajuste
- Predicciones más estables
- Menor costo computacional

5.2 Criterios de selección

1. AIC (Criterio de Información de Akaike):

$$\text{AIC} = n \ln(\text{SCR}/n) + 2(p+1) \tag{23}$$

2. BIC (Criterio de Información Bayesiano):

$$\text{BIC} = n \ln(\text{SCR}/n) + \ln(n)(p+1) \tag{24}$$

BIC penaliza más la complejidad que AIC.
Regla: Menor AIC o BIC $\Rightarrow$ mejor modelo

5.3 Métodos de selección

1. Selección hacia adelante (Forward):

- Comenzar con el modelo vacío (solo intercepto)
- Agregar la variable que más mejora el criterio
- Repetir hasta que ninguna mejora el criterio

2. Eliminación hacia atrás (Backward):

- Comenzar con el modelo completo (todas las variables)
- Eliminar la variable menos significativa
- Repetir hasta que todas sean significativas

3. Selección por pasos (Stepwise):

- Combina forward y backward
- En cada paso, puede agregar o eliminar variables

Advertencia: Estos métodos son heurísticos y pueden no encontrar el mejor modelo. Es recomendable combinarlos con conocimiento del dominio.

6 Regresión Polinomial

6.1 Motivación

Cuando la relación entre X e Y no es lineal, podemos ajustar un polinomio:

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + \cdots + \beta_d X_i^d + \epsilon_i \tag{25}$$

donde d es el grado del polinomio.

Nota: Aunque la relación con X no es lineal, el modelo sigue siendo **lineal en los parámetros** β_j, por lo que se puede usar MCO.

6.2 Implementación

Crear nuevas variables:

- $X_1 = X$
- $X_2 = X^2$
- $X_3 = X^3$, etc.

Luego ajustar una regresión lineal múltiple estándar.

6.3 Selección del grado d

Métodos:

- Validación cruzada
- Criterios de información (AIC, BIC)
- Análisis visual de ajuste

Advertencia: Polinomios de grado muy alto pueden sobreajustar los datos.

7 Correlación

7.1 Correlación de Pearson

Mide la **fuerza y dirección** de la relación lineal entre dos variables X e Y:

$$r_{XY} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2}\sqrt{\sum_{i=1}^n (Y_i - \bar{Y})^2}} = \frac{S_{XY}}{\sqrt{S_{XX} S_{YY}}} \tag{26}$$

Propiedades:

- $-1 \leq r_{XY} \leq 1$
- $r_{XY} = 1$: correlación positiva perfecta
- $r_{XY} = -1$: correlación negativa perfecta
- $r_{XY} = 0$: no hay correlación lineal (pero puede haber relación no lineal)

Interpretación:

- $|r| < 0.3$: correlación débil
- $0.3 \leq |r| < 0.7$: correlación moderada
- $|r| \geq 0.7$: correlación fuerte

7.2 Test de significancia

Para probar $H_0 : \rho = 0$ vs $H_1 : \rho \neq 0$:

$$t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}} \sim t_{n-2} \tag{27}$$

Supuestos:

- (X, Y) siguen una distribución normal bivariada
- Relación lineal

7.3 Correlación de Spearman

Uso: Cuando los datos no son normales o la relación es monótona pero no lineal.
Método: Calcular Pearson sobre los **rangos** de X e Y:

$$r_S = 1 - \frac{6\sum_{i=1}^{n} d_i^2}{n(n^2-1)} \tag{28}$$

donde d_i es la diferencia entre los rangos de X_i e Y_i.
Ventajas:

- Robusto a outliers
- No requiere normalidad
- Detecta relaciones monótonas no lineales

7.4 Correlación no implica causalidad

Importante: Una correlación significativa entre X e Y NO implica que X cause Y (o viceversa).
Posibles explicaciones:

- X causa Y
- Y causa X
- Ambas están influenciadas por una tercera variable Z (variable confusora)
- Correlación espuria (coincidencia)

Ejemplo clásico: Alta correlación entre ventas de helados y ahogamientos. No es que los helados causen ahogamientos, sino que ambos aumentan en verano.

8 Análisis de Covarianza (ANCOVA)

8.1 Definición y objetivo

ANCOVA combina ANOVA con regresión lineal. Permite comparar grupos (factor categórico) mientras se ajusta por variables continuas (covariables).
Modelo general:

$$Y_{ij} = \mu + \alpha_i + \beta X_{ij} + \epsilon_{ij} \tag{29}$$

donde:

- Y_{ij}: variable respuesta para la j-ésima observación en el grupo i
- α_i: efecto del grupo i

- X_{ij}: covariable continua
- β: pendiente común (supuesto de pendientes paralelas)
- $\epsilon_{ij} \sim N(0, \sigma^2)$

8.2 ¿Cuándo usar ANCOVA?

Situaciones típicas:

- Comparar tratamientos ajustando por una medida basal (pre-test)
- Reducir error experimental controlando por variables conocidas
- Aumentar la potencia estadística

Ejemplo: Comparar tres dietas (A, B, C) sobre la pérdida de peso, ajustando por peso inicial.

8.3 Supuestos

Además de los supuestos de regresión lineal:

1. **Independencia de la covariable y el tratamiento:** X no debe estar influenciada por el grupo
2. **Pendientes paralelas (homogeneidad de regresión):** La relación entre X e Y es la misma en todos los grupos
3. **Linealidad:** La relación entre la covariable y la respuesta es lineal

8.4 Test de pendientes paralelas

Ajustar el modelo con interacción:

$$Y_{ij} = \mu + \alpha_i + \beta X_{ij} + (\alpha\beta)_i X_{ij} + \epsilon_{ij} \tag{30}$$

Hipótesis:

$$H_0 : (\alpha\beta)_1 = (\alpha\beta)_2 = \cdots = 0 \quad \text{(pendientes iguales)}$$

Si no rechazamos H_0, procedemos con ANCOVA. Si la rechazamos, las pendientes difieren y ANCOVA no es apropiado.

8.5 Interpretación de resultados

Después de ajustar por la covariable:

- **Efecto de la covariable:** $\hat{\beta}$ cuantifica cuánto cambia Y por unidad de X
- **Efecto del grupo:** $\hat{\alpha}_i$ son las diferencias entre grupos **ajustadas** por X

Ventaja principal: ANCOVA reduce el error residual al explicar parte de la variabilidad con la covariable, aumentando la potencia para detectar diferencias entre grupos.

9 Implementación en Python y R

9.1 Regresión lineal simple en Python

```python
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import statsmodels.api as sm
from statsmodels.formula.api import ols

# Datos de ejemplo
data = pd.DataFrame({
    'X': [1, 2, 3, 4, 5, 6, 7, 8, 9, 10],
    'Y': [2.1, 4.3, 5.8, 8.2, 10.1, 11.8, 14.2, 15.9, 18.1, 20.3]
})

# Ajustar modelo
model = ols('Y ~ X', data=data).fit()

# Resumen del modelo
print(model.summary())

# Coeficientes
print(f"Intercepto: {model.params['Intercept']:.3f}")
print(f"Pendiente: {model.params['X']:.3f}")
print(f"R^2: {model.rsquared:.3f}")

# Grafico
plt.figure(figsize=(8, 5))
plt.scatter(data['X'], data['Y'], label='Datos')
plt.plot(data['X'], model.fittedvalues, 'r-', label='Ajuste')
plt.xlabel('X')
plt.ylabel('Y')
plt.legend()
plt.show()
```

Listing 1: Regresión lineal simple con statsmodels

9.2 Diagnóstico en Python

```python
import matplotlib.pyplot as plt
import scipy.stats as stats

fig, axes = plt.subplots(2, 2, figsize=(12, 10))

# 1. Residuos vs Valores Ajustados
axes[0, 0].scatter(model.fittedvalues, model.resid)
axes[0, 0].axhline(0, color='red', linestyle='--')
axes[0, 0].set_xlabel('Valores Ajustados')
axes[0, 0].set_ylabel('Residuos')
axes[0, 0].set_title('Residuos vs Ajustados')

# 2. Q-Q Plot
stats.probplot(model.resid, dist="norm", plot=axes[0, 1])
axes[0, 1].set_title('Q-Q Plot')

# 3. Scale-Location
residuos_std = np.sqrt(np.abs(model.resid_pearson))
axes[1, 0].scatter(model.fittedvalues, residuos_std)
axes[1, 0].set_xlabel('Valores Ajustados')
axes[1, 0].set_ylabel('Raiz(|Residuos Estand.|)')
axes[1, 0].set_title('Scale-Location')
```

```python

# 4. Residuos vs Leverage
influence = model.get_influence()
leverage = influence.hat_matrix_diag
axes[1, 1].scatter(leverage, model.resid_pearson)
axes[1, 1].set_xlabel('Leverage')
axes[1, 1].set_ylabel('Residuos Estandarizados')
axes[1, 1].set_title('Residuos vs Leverage')

plt.tight_layout()
plt.show()
```

Listing 2: Gráficos de diagnóstico

9.3 Regresión múltiple en R

```r
# Cargar datos
data(mtcars)

# Ajustar modelo
modelo <- lm(mpg ~ wt + hp + cyl, data = mtcars)

# Resumen
summary(modelo)

# Coeficientes
coef(modelo)

# R^2 y R^2 ajustado
summary(modelo)$r.squared
summary(modelo)$adj.r.squared

# ANOVA
anova(modelo)

# Intervalos de confianza
confint(modelo)

# Prediccion
nuevos_datos <- data.frame(wt = 3.0, hp = 150, cyl = 6)
predict(modelo, nuevos_datos, interval = "prediction")
```

Listing 3: Regresión múltiple en R

9.4 Selección de variables en R

```r
# Modelo completo
modelo_completo <- lm(mpg ~ ., data = mtcars)

# Seleccion stepwise (ambas direcciones)
modelo_step <- step(modelo_completo, direction = "both")

# Resumen del modelo seleccionado
summary(modelo_step)

# AIC y BIC
AIC(modelo_step)
BIC(modelo_step)
```

Listing 4: Selección stepwise

9.5 ANCOVA en Python

```python
import pandas as pd
from statsmodels.formula.api import ols
from statsmodels.stats.anova import anova_lm

# Datos de ejemplo: efecto de dieta sobre peso, ajustando por peso inicial
data = pd.DataFrame({
    'peso_final': [72, 68, 75, 70, 65, 78, 71, 69, 73, 67],
    'peso_inicial': [80, 78, 85, 82, 75, 88, 81, 79, 84, 76],
    'dieta': ['A', 'A', 'A', 'B', 'B', 'B', 'C', 'C', 'C', 'C']
})

# Modelo ANCOVA
modelo_ancova = ols('peso_final ~ C(dieta) + peso_inicial',
                    data=data).fit()

# Tabla ANOVA
print(anova_lm(modelo_ancova, typ=2))

# Resumen
print(modelo_ancova.summary())

# Test de pendientes paralelas (interaccion)
modelo_interaccion = ols('peso_final ~ C(dieta) * peso_inicial',
                         data=data).fit()
print(anova_lm(modelo_interaccion, typ=2))
```

Listing 5: ANCOVA con statsmodels

10 Ejercicios Propuestos

10.1 Ejercicio 1: Regresión lineal simple

Se midió la altura (X, en cm) y el peso (Y, en kg) de 15 estudiantes. Los datos se resumen:

$$\bar{X} = 170, \quad \bar{Y} = 68, \quad S_{XX} = 450, \quad S_{YY} = 280, \quad S_{XY} = 330$$

Tareas:

1. Calcular las estimaciones $\hat{\beta}_0$ y $\hat{\beta}_1$
2. Interpretar los coeficientes
3. Calcular R^2
4. Predecir el peso de un estudiante de 175 cm

10.2 Ejercicio 2: Diagnóstico

Ajustaste una regresión lineal y observaste en el gráfico de residuos vs ajustados un patrón en forma de embudo.

Preguntas:

1. ¿Qué supuesto se viola?
2. ¿Qué consecuencias tiene?
3. Proponer dos posibles soluciones

10.3 Ejercicio 3: Regresión múltiple

Se ajustó un modelo de regresión múltiple para predecir el precio de autos usados (Y) en función de:

- X_1: antigüedad (años)
- X_2: kilometraje (miles)
- X_3: potencia del motor (HP)

El modelo ajustado es:

$$\hat{Y} = 25000 - 1500X_1 - 0.05X_2 + 100X_3$$

Tareas:

1. Interpretar cada coeficiente
2. Si un auto tiene 3 años, 50,000 km y 150 HP, ¿cuál es su precio estimado?
3. ¿Qué variable tiene mayor impacto absoluto en el precio?

10.4 Ejercicio 4: Multicolinealidad

Se ajustó un modelo con las variables: estatura (X_1), peso (X_2) y circunferencia de cintura (X_3) para predecir presión arterial. Los VIF son:

$$\text{VIF}_1 = 2.3, \quad \text{VIF}_2 = 15.2, \quad \text{VIF}_3 = 14.8$$

Preguntas:

1. ¿Hay multicolinealidad? ¿Entre qué variables?
2. ¿Qué harías para solucionarlo?

10.5 Ejercicio 5: Correlación

Se calculó la correlación de Pearson entre horas de estudio (X) y calificación en un examen (Y) para 50 estudiantes, obteniendo $r = 0.72$.

Tareas:

1. Interpretar el valor de r
2. Realizar el test de significancia ($\alpha = 0.05$)
3. Calcular R^2 y explicar su significado
4. ¿Podemos concluir que estudiar más causa mejores notas? Justificar

11 Referencias

- Kutner, M. H., Nachtsheim, C. J., Neter, J., & Li, W. (2005). *Applied Linear Statistical Models* (5th ed.). McGraw-Hill/Irwin.
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning with Applications in R* (2nd ed.). Springer.

- Montgomery, D. C., Peck, E. A., & Vining, G. G. (2012). *Introduction to Linear Regression Analysis* (5th ed.). Wiley.
- Fox, J. (2015). *Applied Regression Analysis and Generalized Linear Models* (3rd ed.). SAGE Publications.
- Faraway, J. J. (2014). *Linear Models with R* (2nd ed.). CRC Press.