

Aprendizaje Supervisado

Clase 21: Ensamblados y Random Forest

Dr. José Bavio

Departamento de Matemática
Universidad Nacional del Sur

2026

Contenido de la clase

- 1 La idea de los ensambles
- 2 Bagging
- 3 Random Forest
- 4 Estimación Out-of-Bag
- 5 Importancia de Variables
- 6 Hiperparámetros y Práctica

¿Por qué combinar modelos?

Problema

Un árbol de decisión tiene alta varianza: cambiás un poco los datos y el árbol cambia drásticamente.

Intuición: la sabiduría de la multitud

Si le preguntás a una sola persona cuántos caramelos hay en un frasco, puede errar por mucho. Si promediás las respuestas de 100 personas independientes, el promedio suele ser muy preciso. Los **métodos de ensamble** hacen exactamente eso con modelos.

Condición clave: los modelos deben ser **suficientemente distintos entre sí**. Promediar 100 copias del mismo modelo no ayuda nada.

Antes de entender bagging, necesitamos el **bootstrap**.

Muestra bootstrap

Dado un conjunto $\mathcal{D}$ de n observaciones, una muestra bootstrap $\mathcal{D}^{(b)}$ es una muestra de tamaño n extraída **con reemplazo** de $\mathcal{D}$.

Coloquialmente

Es como sacar bolitas de una bolsa y volver a meterlas antes del próximo sorteo. Algunas bolitas van a salir dos veces, otras ninguna. En promedio, una muestra bootstrap contiene el $\approx 63.2\%$ de las observaciones originales (distintas).

Las observaciones que no entran en la muestra bootstrap ($\approx 36.8\%$) se llaman **out-of-bag** (OOB). Ya veremos por qué eso es útil.

Bagging (*Bootstrap Aggregating*)

Algoritmo (Breiman, 1996):

- ❶ Para $b = 1, \dots, B$:
 - ❶ Generar una muestra bootstrap $\mathcal{D}^{(b)}$.
 - ❷ Entrenar un árbol $T^{(b)}$ sobre $\mathcal{D}^{(b)}$.
- ❷ Combinar por **mayoría de votos**:

$$\hat{y}(x) = \arg \max_k \sum_{b=1}^B 1(\hat{y}^{(b)}(x) = k)$$

¿Por qué reduce la varianza?

Si un modelo tiene varianza σ^2 y los modelos son independientes, el promedio de B tiene varianza σ^2/B . La varianza cae con B . El sesgo queda igual.

El problema del bagging puro

Problema: correlación entre árboles

Si hay un feature muy predictivo (por ejemplo, una variable que domina la predicción), **todos** los árboles van a usarla en los primeros splits.

Resultado: los B árboles son muy parecidos entre sí.

Promediarlos no reduce mucho la varianza.

Analogía

Preguntarle a 100 personas que leyeron exactamente el mismo artículo no es más informativo que preguntarle a una sola. Para que el promedio ayude, las fuentes deben ser **distintas**.

Random Forest: decorrelación de árboles

Ingrediente extra de Random Forest (Breiman, 2001)

En cada split de cada árbol, se elige el mejor split **solo entre un subconjunto aleatorio** de m features (no los p totales).

- Clasificación: $m = \lfloor \sqrt{p} \rfloor$ (por defecto)
- Regresión: $m = \lfloor p/3 \rfloor$ (por defecto)

¿Por qué funciona?

Al forzar que cada árbol ignore la mayoría de los features en cada split, los árboles se “ven obligados” a ser distintos entre sí. Cuando se promedian árboles poco correlacionados, la varianza cae mucho más.

Varianza del promedio: por qué la decorrelación importa

Sean B árboles, cada uno con varianza σ^2 y correlación ρ entre pares. La varianza del promedio es:

$$\rho \sigma^2 + \frac{1 - \rho}{B} \sigma^2$$

- Si $B \rightarrow \infty$: la varianza tiende a $\rho \sigma^2$.
- Si $\rho = 0$ (árboles independientes): varianza $\rightarrow 0$.
- Si $\rho = 1$ (árboles idénticos): varianza $= \sigma^2$ (sin mejora).

Conclusión práctica

Aumentar B (más árboles) siempre ayuda, pero con rendimientos decrecientes. Reducir ρ (decorrelación vía aleatoriedad en features) es lo que hace único a RF.

Error Out-of-Bag (OOB)

Idea

Cada árbol $T^{(b)}$ se entrenó sobre $\mathcal{D}^{(b)}$ que excluye $\approx 36.8\%$ de los datos. Esas observaciones son las **OOB** de ese árbol. Para cada x_i , predecir usando **solo** los árboles que no vieron x_i .

$$\hat{y}_i^{\text{OOB}} = \arg \max_k \sum_{b: i \in \text{OOB}(b)} 1(\hat{y}^{(b)}(x_i) = k)$$

¿Para qué sirve?

El error OOB es un estimador **casi insesgado del error de generalización** y no requiere reservar un conjunto de validación separado.

Es como tener validación cruzada “gratis” mientras entrenás.

Importancia por impureza (MDI)

Mean Decrease in Impurity (MDI)

La importancia de la variable j es la reducción total de impureza (Gini/entropía) acumulada en todos los splits de todos los árboles que usan j , promediada sobre B .

Coloquialmente

Una variable es “importante” según MDI si, cada vez que se la usa para hacer un split, los nodos hijos quedan mucho más puros que el padre.

Si una variable hace splits que no mejoran casi nada la pureza, su importancia es baja.

Cuidado

MDI **sobreestima** la importancia de variables con alta cardinalidad (muchos valores posibles, como IDs o fechas). Es un sesgo conocido del método.

Importancia por permutación (MDA)

Mean Decrease in Accuracy (MDA)

Para cada árbol y cada variable j :

- 1 Calcular el error OOB base.
- 2 **Permutar aleatoriamente** los valores de x_j en el conjunto OOB.
- 3 Recalcular el error con los valores permutados.
- 4 Importancia de j = aumento promedio del error.

Intuición

Si mezclar al azar los valores de una variable arruina las predicciones, esa variable era importante.

Si el modelo no se entera de que la mezclamos, era ruido.

Es como preguntarse: “¿qué pasa si le saco esta pieza al motor?”

Hiperparámetros principales de Random Forest

Hiperparámetro	Efecto	Valor típico
<code>n_estimators</code>	Número de árboles	100–500
<code>max_features</code>	Features por split	'sqrt'
<code>max_depth</code>	Prof. máxima del árbol	None
<code>min_samples_leaf</code>	Mínimo muestras en hoja	1–5
<code>bootstrap</code>	Usar muestras bootstrap	True
<code>oob_score</code>	Calcular error OOB	True

Regla práctica

Más árboles (`n_estimators`) casi siempre mejora o mantiene igual el rendimiento: no existe “sobreajuste por tener demasiados árboles”. El límite es computacional, no de precisión.

Ventajas y limitaciones de Random Forest

Ventajas

- Muy robusto: difícil hacerlo sobreajustar
- Buena estimación de error OOB
- Importancia de variables incorporada
- Pocas decisiones de diseño
- Paralelizable

Limitaciones

- Caja negra: no podés explicar una predicción puntual fácilmente
- Lento para predecir en tiempo real (muchos árboles)
- Memoria: guarda B árboles completos
- No extrapola bien fuera del rango de entrenamiento

- Los **métodos de ensamble** combinan múltiples modelos débiles para obtener uno robusto.
- **Bagging** reduce la varianza entrenando sobre muestras bootstrap y promediando.
- **Random Forest** agrega aleatoriedad en la selección de features para **decorrelacionar** los árboles.
- El **error OOB** es una estimación gratuita del error de generalización.
- La **importancia de variables** (MDI y MDA) permite interpretar el modelo de forma global.

Próxima clase: SVM y KNN — dos enfoques muy distintos al problema de clasificación.