Unidad 4: ANOVA y Diseño de Experimentos

Clase 1: Introducción a ANOVA de un Factor

Métodos de Análisis de Datos 1

Departamento de Matemática
Universidad Nacional del Sur

Primer Semestre 2026

Contenido

1. Introducción al ANOVA
2. Modelo ANOVA de un Factor
3. Descomposición de Variabilidad
4. Tabla ANOVA y Estadístico F
5. Interpretación Geométrica
6. Conclusiones

¿Qué es ANOVA?

ANOVA = Analysis of Variance (Análisis de Varianza)

Definición

Técnica estadística para comparar las medias de tres o más grupos simultáneamente.

¿Por qué no usar múltiples pruebas t?

- Con k grupos: $\binom{k}{2} = \frac{k(k-1)}{2}$ comparaciones
- Para 4 grupos: 6 comparaciones
- El error tipo I se acumula: $\alpha_{\text{total}} = 1 - (1-\alpha)^m$
- Con $\alpha = 0.05$ y 6 comparaciones: $\alpha_{\text{total}} \approx 0.26$

ANOVA controla el error tipo I familiar

Principio Básico de ANOVA

ANOVA descompone la variabilidad total en dos componentes:

Variabilidad Entre Grupos

- Explicada por el factor
- Diferencias entre medias grupales
- ¿Es mayor que el ruido?

Variabilidad Dentro de Grupos

- No explicada (error)
- Variabilidad natural
- Ruido del sistema

Idea Central

Si la variabilidad entre grupos es significativamente mayor que la variabilidad dentro de grupos, hay evidencia de que al menos una media difiere.

Ejemplo Motivador

Problema: ¿Cuál método de enseñanza es más efectivo?

Estudiante	Método A	Método B	Método C
1	78	88	75
2	82	90	78
3	79	85	73
4	85	92	80
5	80	87	76
Media	80.8	88.4	76.4

Pregunta: ¿Son estas diferencias estadísticamente significativas o podrían deberse al azar?

ANOVA responde esta pregunta considerando tanto las diferencias entre medias como la variabilidad dentro de cada grupo.

Aplicaciones de ANOVA

Ciencias de la Salud

- Comparar tratamientos médicos
- Estudios de dosis-respuesta
- Efectividad de intervenciones

Psicología

- Diferencias entre grupos de edad
- Efectos de terapias
- Estudios de cognición

Agronomía

- Efecto de fertilizantes
- Variedades de cultivos
- Condiciones ambientales

Manufactura

- Control de calidad
- Comparación de máquinas
- Optimización de procesos

Notación y Estructura de Datos

Configuración:

- k grupos (niveles del factor)
- n_i observaciones en el grupo i
- $N = \sum_{i=1}^{k} n_i$ observaciones totales

Datos:

Grupo 1	Grupo 2	$\cdots$	Grupo k
Y_{11}	Y_{21}	$\cdots$	Y_{k1}
Y_{12}	Y_{22}	$\cdots$	Y_{k2}
$\vdots$	$\vdots$	$\ddots$	$\vdots$
Y_{1n_1}	Y_{2n_2}	$\cdots$	Y_{kn_k}
$\bar{Y}_1$	$\bar{Y}_2$	$\cdots$	$\bar{Y}_k$

donde Y_{ij} es la j-ésima observación del grupo i.

Modelo Estadístico

Modelo de Efectos

$$Y_{ij} = \mu + \tau_i + \varepsilon_{ij}$$

donde:

- Y_{ij}: observación j del grupo i
- μ: media global (efecto común a todos)
- τ_i: efecto del tratamiento i (desviación de la media global)
- ε_{ij}: error aleatorio $\sim N(0, \sigma^2)$

Modelo de Medias

$$Y_{ij} = \mu_i + \varepsilon_{ij}$$

donde $\mu_i = \mu + \tau_i$ es la media del grupo i.

Restricción del Modelo

Para que el modelo sea identificable, se impone una restricción:

Restricción de suma cero

$$\sum_{i=1}^{k} \tau_i = 0$$

Interpretación:

- Los efectos de tratamiento suman cero
- $\tau_i > 0$: el grupo i está por encima de la media global
- $\tau_i < 0$: el grupo i está por debajo de la media global
- Si $\tau_i = 0$ para todo i: no hay efecto de tratamiento

Hipótesis Estadísticas

En términos de medias

$$H_0 : \mu_1 = \mu_2 = \cdots = \mu_k$$
$$H_1 : \text{Al menos una media difiere}$$

En términos de efectos

$$H_0 : \tau_1 = \tau_2 = \cdots = \tau_k = 0$$
$$H_1 : \text{Al menos un } \tau_i \neq 0$$

Nota: H_1 no especifica cuáles medias difieren, solo que hay al menos una diferencia.

Concepto de Descomposición

La variabilidad total de los datos se puede descomponer en dos componentes:

$$\text{Variabilidad Total} = \text{Variabilidad Entre Grupos} + \text{Variabilidad Dentro de Grupos}$$

Descomposición:

- Variabilidad Total (SST) se divide en:
  - Entre Grupos (SSB) - variabilidad explicada
  - Dentro de Grupos (SSW) - variabilidad no explicada (error)

Matemáticamente: $SST = SSB + SSW$

Suma de Cuadrados Total (SST)

Definición

$$\text{SST} = \sum_{i=1}^{k} \sum_{j=1}^{n_i} (Y_{ij} - \bar{Y})^2$$

donde $\bar{Y} = \frac{1}{N} \sum_{i=1}^{k} \sum_{j=1}^{n_i} Y_{ij}$ es la media global.

Interpretación:

- Mide la variabilidad total de todas las observaciones
- Suma de desviaciones cuadradas respecto a la media global
- No considera la estructura de grupos

Grados de libertad: $N - 1$

Suma de Cuadrados Entre Grupos (SSB)

Definición

$$\text{SSB} = \sum_{i=1}^{k} n_i(\bar{Y}_i - \bar{Y})^2$$

donde $\bar{Y}_i = \frac{1}{n_i}\sum_{j=1}^{n_i} Y_{ij}$ es la media del grupo i.

Interpretación:

- Mide la variabilidad explicada por el factor
- Diferencias entre las medias grupales y la media global
- Ponderada por el tamaño de cada grupo (n_i)

Grados de libertad: $k - 1$

Suma de Cuadrados Dentro de Grupos (SSW)

Definición

$$\text{SSW} = \sum_{i=1}^{k} \sum_{j=1}^{n_i} (Y_{ij} - \bar{Y}_i)^2$$

Interpretación:

- Mide la variabilidad no explicada (error)
- Suma de variabilidades dentro de cada grupo
- Refleja la variabilidad natural/ruido del sistema

Grados de libertad: $N - k$

También llamada: SSE (Sum of Squares Error) o SSR (Sum of Squares Residual)

Identidad Fundamental de ANOVA

Descomposición de la Variabilidad

$$\underbrace{\sum_{i=1}^{k}\sum_{j=1}^{n_i}(Y_{ij}-\bar{Y})^2}_{\text{SST}} = \underbrace{\sum_{i=1}^{k} n_i(\bar{Y}_i-\bar{Y})^2}_{\text{SSB}} + \underbrace{\sum_{i=1}^{k}\sum_{j=1}^{n_i}(Y_{ij}-\bar{Y}_i)^2}_{\text{SSW}}$$

Demostración (idea):

$$\begin{aligned} Y_{ij}-\bar{Y} &= (Y_{ij}-\bar{Y}_i)+(\bar{Y}_i-\bar{Y}) \\ &= \text{desviación dentro del grupo} + \text{desviación entre grupos} \end{aligned}$$

Al elevar al cuadrado y sumar, los términos cruzados se cancelan.

Ejemplo Numérico: Datos

Tres métodos de enseñanza:

	Método A	Método B	Método C
	78	88	75
	82	90	78
	79	85	73
	85	92	80
	80	87	76
$\bar{Y}_i$	80.8	88.4	76.4
n_i	5	5	5

Media global: $\bar{Y} = \frac{80.8+88.4+76.4}{3} = 81.87$
$N = 15$ observaciones totales

Ejemplo Numérico: Cálculo SST

$$\text{SST} = \sum_{i=1}^{3}\sum_{j=1}^{5}(Y_{ij} - \bar{Y})^2$$

Grupo A:

$$(78 - 81.87)^2 + (82 - 81.87)^2 + (79 - 81.87)^2$$
$$+ (85 - 81.87)^2 + (80 - 81.87)^2 = 38.93$$

Grupo B:

$$(88 - 81.87)^2 + (90 - 81.87)^2 + \cdots = 271.73$$

Grupo C:

$$(75 - 81.87)^2 + (78 - 81.87)^2 + \cdots = 177.73$$

$\text{SST} = 38.93 + 271.73 + 177.73 = 488.39$

Ejemplo Numérico: Cálculo SSB

$$\text{SSB} = \sum_{i=1}^{3} n_i(\bar{Y}_i - \bar{Y})^2$$

$$\begin{aligned}
\text{SSB} &= 5(80.8 - 81.87)^2 + 5(88.4 - 81.87)^2 + 5(76.4 - 81.87)^2 \\
&= 5(1.14) + 5(42.64) + 5(29.92) \\
&= 5.70 + 213.20 + 149.60 \\
&= 368.50
\end{aligned}$$

Interpretación: El factor "método de enseñanza" explica 368.50 unidades de variabilidad.

Ejemplo Numérico: Cálculo SSW

$$\text{SSW} = \sum_{i=1}^{3}\sum_{j=1}^{5}(Y_{ij} - \bar{Y}_i)^2$$

Grupo A ($\bar{Y}_A = 80.8$):

$$(78 - 80.8)^2 + (82 - 80.8)^2 + (79 - 80.8)^2$$
$$+ (85 - 80.8)^2 + (80 - 80.8)^2 = 29.20$$

Grupo B ($\bar{Y}_B = 88.4$): 42.80
Grupo C ($\bar{Y}_C = 76.4$): 47.20

$\text{SSW} = 29.20 + 42.80 + 47.20 = 119.20$

Verificación: $\text{SSB} + \text{SSW} = 368.50 + 119.20 = 487.70 \approx 488.39$ ✓

Cuadrados Medios

Las sumas de cuadrados se dividen por sus grados de libertad para obtener cuadrados medios:

Cuadrado Medio Entre Grupos (MSB)

$$\text{MSB} = \frac{\text{SSB}}{k-1}$$

Estima $\sigma^2 + n \cdot \text{Var}(\tau_i)$ bajo H_1

Cuadrado Medio Dentro de Grupos (MSW)

$$\text{MSW} = \frac{\text{SSW}}{N-k}$$

Estima σ^2 (varianza del error) bajo H_0 y H_1

Estadístico F

Definición

$$F = \frac{\text{MSB}}{\text{MSW}} = \frac{\text{SSB}/(k-1)}{\text{SSW}/(N-k)}$$

Distribución bajo H_0:

$$F \sim F_{k-1,N-k}$$

Interpretación:

- Compara variabilidad entre grupos vs. variabilidad dentro de grupos
- Si F es grande: mucha variabilidad entre grupos relativa al error
- Si H_0 es cierta: $F \approx 1$ (ambos cuadrados medios estiman σ^2)
- Si H_1 es cierta: $F > 1$ (MSB sobreestima σ^2)

Tabla ANOVA Completa

Fuente	Suma de Cuadrados	GL	Cuadrados Medios	F
Entre grupos	SSB	$k-1$	$\frac{\text{SSB}}{k-1}$	$\frac{\text{MSB}}{\text{MSW}}$
Dentro de grupos	SSW	$N-k$	$\frac{\text{SSW}}{N-k}$	
Total	SST	$N-1$		

Grados de libertad:

- Total: $N-1$ (una restricción: estimar $\bar{Y}$)
- Entre grupos: $k-1$ (estimar k medias con restricción $\sum \tau_i = 0$)
- Dentro de grupos: $N-k$ (estimar variabilidad en cada grupo)

Ejemplo Numérico: Tabla ANOVA

Con los datos anteriores:

Fuente	SS	GL	MS	F	p-valor
Entre grupos	368.50	2	184.25	18.52	< 0.001
Dentro de grupos	119.20	12	9.93		
Total	487.70	14			

Cálculos:

- $\text{MSB} = 368.50/2 = 184.25$
- $\text{MSW} = 119.20/12 = 9.93$
- $F = 184.25/9.93 = 18.52$
- Valor crítico $F_{2,12,0.05} = 3.89$
- $18.52 > 3.89 \Rightarrow$ Rechazamos H_0

Regla de Decisión

Prueba de Hipótesis

- **Rechazar H_0 si:** $F > F_{k-1,N-k,\alpha}$
- **O equivalentemente:** p-valor $< \alpha$

Interpretación de resultados:

- **Si rechazamos H_0:** Hay evidencia estadística de que al menos una media difiere. Proceder con comparaciones post-hoc.
- **Si no rechazamos H_0:** No hay evidencia suficiente de diferencias entre las medias. Los datos son consistentes con $\mu_1 = \mu_2 = \cdots = \mu_k$.

Visualización de la Descomposición

Desviación total = Desviación entre grupos + Desviación dentro de grupos

$$(Y_{ij} - \bar{Y}) = (\bar{Y}_i - \bar{Y}) + (Y_{ij} - \bar{Y}_i)$$

Casos Extremos

H_0 es cierta

- Medias grupales similares
- SSB pequeño
- $F \approx 1$

H_1 es cierta

- Medias grupales muy distintas
- SSB grande
- $F \gg 1$

Distribución F

Características:

- Siempre positiva ($F \geq 0$)
- Asimétrica (sesgada a la derecha)
- Forma depende de los grados de libertad ($k-1, N-k$)
- Área a la derecha del valor crítico $= \alpha$

Resumen de la Clase

1. **ANOVA** permite comparar medias de $k \geq 3$ grupos controlando el error tipo I
2. El **modelo** descompone cada observación en: media global + efecto de tratamiento + error
3. La **variabilidad total** se descompone en: variabilidad entre grupos + variabilidad dentro de grupos
4. El **estadístico F** compara estas variabilidades: $F = \text{MSB}/\text{MSW}$
5. La **tabla ANOVA** organiza todos los cálculos para tomar una decisión
6. Si rechazamos H_0, sabemos que hay diferencias pero no cuáles grupos difieren

Próxima Clase

Temas a cubrir:

- **Supuestos de ANOVA:** normalidad, homocedasticidad, independencia
- **Verificación de supuestos:** pruebas y gráficos diagnósticos
- **Comparaciones múltiples post-hoc:** Tukey, Bonferroni, Scheffé
- **Tamaño del efecto:** η^2 (eta cuadrado)
- **Potencia estadística** del ANOVA

Lectura recomendada: Secciones 2-3 del PDF de teoría de la Unidad 4

¿Preguntas?

Unidad 4 - Clase 1
ANOVA de un Factor

Métodos de Análisis de Datos 1
UNS - 2026