Unidad 4: ANOVA y Diseño de Experimentos

Métodos de Análisis de Datos 1

Departamento de Matemática
Universidad Nacional del Sur

Primer Semestre 2026

Contents

1 Introducción **3**
1.1 Aplicaciones . . . 3

2 ANOVA de un Factor **3**
2.1 Modelo Estadístico . . . 3
2.2 Hipótesis a Contrastar . . . 4
2.3 Descomposición de la Variabilidad . . . 4
2.4 Tabla ANOVA . . . 4
2.5 Estadístico F y Decisión . . . 5
2.6 Supuestos del ANOVA . . . 5
2.7 Tamaño del Efecto: η^2 (Eta Cuadrado) . . . 5

3 Comparaciones Múltiples Post-Hoc **5**
3.1 Test de Tukey HSD . . . 6
3.2 Corrección de Bonferroni . . . 6
3.3 Test de Scheffé . . . 6
3.4 Comparación de Métodos . . . 6

4 ANOVA de Dos Factores **7**
4.1 Modelo Estadístico . . . 7
4.2 Efectos Principales e Interacción . . . 7
4.3 Tabla ANOVA de Dos Factores . . . 7

5 Diseños Experimentales Básicos **8**
5.1 Principios Básicos del Diseño Experimental . . . 8
5.2 Diseño Completamente Aleatorizado (DCA) . . . 8
5.3 Diseño en Bloques Completos Aleatorizados (DBCA) . . . 8
5.4 Diseño en Cuadrado Latino . . . 9

6 ANOVA de Medidas Repetidas **9**
6.1 Modelo y Supuestos . . . 9
6.2 Verificación de Esfericidad . . . 9

7 Implementación Computacional **9**
7.1 ANOVA en Python . . . 9
7.1.1 ANOVA de un factor con scipy . . . 10
7.1.2 ANOVA con statsmodels y post-hoc . . . 10
7.1.3 ANOVA de dos factores . . . 11

7.2 ANOVA en R 11
7.2.1 ANOVA de un factor en R 11
7.2.2 ANOVA de dos factores en R 12
7.2.3 Diseño en Bloques Completos Aleatorizados 12

8 Ejercicios Propuestos **13**
8.1 Ejercicio 1: ANOVA de un factor 13
8.2 Ejercicio 2: ANOVA de dos factores 13
8.3 Ejercicio 3: Diseño en Bloques 14
8.4 Ejercicio 4: Análisis Completo 14

9 Conclusiones **14**

1 Introducción

El Análisis de Varianza (ANOVA, por sus siglas en inglés *Analysis of Variance*) es una técnica estadística fundamental para comparar las medias de tres o más grupos. Mientras que las pruebas t permiten comparar dos grupos, ANOVA extiende este concepto a múltiples grupos simultáneamente, controlando el error tipo I que se acumularía al realizar múltiples comparaciones por pares.

El principio básico de ANOVA es descomponer la variabilidad total de los datos en componentes: variabilidad entre grupos (explicada por el factor) y variabilidad dentro de los grupos (no explicada, o error). Si la variabilidad entre grupos es significativamente mayor que la variabilidad dentro de los grupos, hay evidencia de que al menos una media grupal difiere de las demás.

1.1 Aplicaciones

ANOVA se utiliza en una amplia variedad de contextos:

- **Medicina:** Comparar la efectividad de diferentes tratamientos
- **Agronomía:** Evaluar el efecto de distintos fertilizantes en el rendimiento de cultivos
- **Psicología:** Analizar diferencias en desempeño cognitivo entre grupos de edad
- **Manufactura:** Estudiar el efecto de diferentes máquinas o procesos en la calidad del producto
- **Marketing:** Comparar la efectividad de diferentes estrategias publicitarias

2 ANOVA de un Factor

2.1 Modelo Estadístico

El modelo ANOVA de un factor (o de una vía) considera una variable respuesta cuantitativa Y y un factor categórico con k niveles o grupos. El modelo estadístico es:

$$Y_{ij} = \mu + \tau_i + \varepsilon_{ij} \tag{1}$$

donde:

- Y_{ij} es la j-ésima observación del grupo i
- μ es la media global
- τ_i es el efecto del tratamiento i (con $i = 1, 2, \ldots, k$)
- $\varepsilon_{ij} \sim N(0, \sigma^2)$ es el error aleatorio
- $j = 1, 2, \ldots, n_i$ (donde n_i es el número de observaciones en el grupo i)

El modelo puede expresarse equivalentemente como:

$$Y_{ij} = \mu_i + \varepsilon_{ij} \tag{2}$$

donde $\mu_i = \mu + \tau_i$ es la media del grupo i.

2.2 Hipótesis a Contrastar

Las hipótesis del ANOVA de un factor son:

$$H_0 : \mu_1 = \mu_2 = \cdots = \mu_k \quad \text{(todas las medias son iguales)}$$
$$H_1 : \text{Al menos una media difiere de las demás}$$

Equivalentemente, en términos de los efectos:

$$H_0 : \tau_1 = \tau_2 = \cdots = \tau_k = 0$$
$$H_1 : \text{Al menos un } \tau_i \neq 0$$

2.3 Descomposición de la Variabilidad

ANOVA descompone la variabilidad total (SST, *Sum of Squares Total*) en dos componentes:

$$\text{SST} = \text{SSB} + \text{SSW} \tag{3}$$

donde:

- **SST (Suma de Cuadrados Total):** Variabilidad total de los datos

$$\text{SST} = \sum_{i=1}^{k} \sum_{j=1}^{n_i} (Y_{ij} - \bar{Y})^2 \tag{4}$$

- **SSB (Suma de Cuadrados Entre Grupos):** Variabilidad explicada por el factor

$$\text{SSB} = \sum_{i=1}^{k} n_i (\bar{Y}_i - \bar{Y})^2 \tag{5}$$

- **SSW (Suma de Cuadrados Dentro de Grupos):** Variabilidad no explicada (error)

$$\text{SSW} = \sum_{i=1}^{k} \sum_{j=1}^{n_i} (Y_{ij} - \bar{Y}_i)^2 \tag{6}$$

Aquí, $\bar{Y}$ es la media global y $\bar{Y}_i$ es la media del grupo i.

2.4 Tabla ANOVA

Los resultados se resumen en la tabla ANOVA:

Fuente	Suma de Cuadrados	GL	Cuadrados Medios	Estadístico F
Entre grupos	SSB	$k-1$	MSB = SSB/(k-1)	$F = \frac{\text{MSB}}{\text{MSW}}$
Dentro de grupos	SSW	$N-k$	MSW = SSW/(N-k)	
Total	SST	$N-1$		

Table 1: Tabla ANOVA de un factor

donde $N = \sum_{i=1}^{k} n_i$ es el número total de observaciones.

2.5 Estadístico F y Decisión

El estadístico F compara la variabilidad entre grupos con la variabilidad dentro de grupos:

$$F = \frac{\text{MSB}}{\text{MSW}} \tag{7}$$

Bajo H_0, este estadístico sigue una distribución $F_{k-1,N-k}$. Se rechaza H_0 si:

$$F > F_{k-1,N-k,\alpha} \tag{8}$$

o equivalentemente, si el p-valor $< \alpha$.

2.6 Supuestos del ANOVA

Para que los resultados del ANOVA sean válidos, deben cumplirse tres supuestos:

1. **Independencia:** Las observaciones deben ser independientes entre sí
2. **Normalidad:** Los errores ε_{ij} siguen una distribución normal (o equivalentemente, Y_{ij} es normal en cada grupo)
3. **Homocedasticidad:** La varianza es constante en todos los grupos: $\text{Var}(Y_{ij}) = \sigma^2$ para todo i

Verificación de supuestos:

- **Normalidad:** Gráfico Q-Q de residuos, test de Shapiro-Wilk
- **Homocedasticidad:** Test de Levene, test de Bartlett, gráfico de residuos vs. valores ajustados

2.7 Tamaño del Efecto: η^2 (Eta Cuadrado)

El tamaño del efecto mide la proporción de variabilidad explicada por el factor:

$$\eta^2 = \frac{\text{SSB}}{\text{SST}} \tag{9}$$

Interpretación (reglas generales de Cohen):

- $\eta^2 < 0.06$: efecto pequeño
- $0.06 \leq \eta^2 < 0.14$: efecto mediano
- $\eta^2 \geq 0.14$: efecto grande

3 Comparaciones Múltiples Post-Hoc

Si el ANOVA rechaza H_0, sabemos que al menos una media difiere, pero no sabemos cuáles. Las pruebas post-hoc permiten identificar qué pares de grupos son significativamente diferentes, controlando el error tipo I acumulado.

3.1 Test de Tukey HSD

El test HSD (*Honestly Significant Difference*) de Tukey es el más utilizado cuando todas las comparaciones por pares son de interés y los tamaños muestrales son iguales o similares.

Para cada par de grupos i y j, se calcula:

$$\text{HSD} = q_{\alpha,k,N-k}\sqrt{\frac{\text{MSW}}{n}} \tag{10}$$

donde $q_{\alpha,k,N-k}$ es el valor crítico de la distribución del rango estudentizado. Dos grupos difieren significativamente si:

$$|\bar{Y}_i - \bar{Y}_j| > \text{HSD} \tag{11}$$

3.2 Corrección de Bonferroni

El método de Bonferroni es más conservador y controla el error tipo I familiar ajustando el nivel de significancia:

$$\alpha_{\text{ajustado}} = \frac{\alpha}{m} \tag{12}$$

donde m es el número de comparaciones. Para k grupos, $m = \binom{k}{2} = \frac{k(k-1)}{2}$.

Ventaja: Simple y muy conservador.

Desventaja: Puede ser demasiado conservador (baja potencia) cuando hay muchas comparaciones.

3.3 Test de Scheffé

El método de Scheffé es el más conservador y permite realizar cualquier tipo de contraste lineal, no solo comparaciones por pares. Es útil cuando se desean hacer comparaciones complejas o no planificadas.

El valor crítico es:

$$S = \sqrt{(k-1)F_{k-1,N-k,\alpha}} \tag{13}$$

Dos grupos difieren si:

$$|\bar{Y}_i - \bar{Y}_j| > S\sqrt{\text{MSW}\left(\frac{1}{n_i} + \frac{1}{n_j}\right)} \tag{14}$$

3.4 Comparación de Métodos

Método	Ventajas	Cuándo usar
Tukey HSD	Potente para comparaciones por pares, controla error familiar	Comparar todos los pares, tamaños similares
Bonferroni	Simple, muy conservador	Pocas comparaciones planificadas
Scheffé	Más flexible, permite contrastes complejos	Comparaciones no planificadas o contrastes complejos

Table 2: Comparación de métodos post-hoc

4 ANOVA de Dos Factores

El ANOVA de dos factores (o de dos vías) permite estudiar simultáneamente el efecto de dos factores categóricos sobre una variable respuesta, así como su interacción.

4.1 Modelo Estadístico

El modelo para dos factores A (con a niveles) y B (con b niveles) es:

$$Y_{ijk} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + \varepsilon_{ijk} \tag{15}$$

donde:

- μ es la media global
- α_i es el efecto principal del factor A (nivel i)
- β_j es el efecto principal del factor B (nivel j)
- $(\alpha\beta)_{ij}$ es el efecto de interacción entre A y B
- $\varepsilon_{ijk} \sim N(0, \sigma^2)$ es el error aleatorio
- $k = 1, 2, \ldots, n_{ij}$ (réplicas en la celda ij)

4.2 Efectos Principales e Interacción

- **Efecto principal del factor A:** Diferencia promedio entre niveles de A, ignorando B
- **Efecto principal del factor B:** Diferencia promedio entre niveles de B, ignorando A
- **Interacción A×B:** El efecto de un factor depende del nivel del otro factor

Interpretación de la interacción:

- Si la interacción es significativa, los efectos principales pueden no ser informativos por sí solos
- Gráficamente, las líneas de perfiles no son paralelas cuando hay interacción
- Si no hay interacción, las líneas son aproximadamente paralelas

4.3 Tabla ANOVA de Dos Factores

Fuente	Suma de Cuadrados	GL	Cuadrados Medios
Factor A	SS_A	$a-1$	$\text{MS}_A = \text{SS}_A/(a-1)$
Factor B	SS_B	$b-1$	$\text{MS}_B = \text{SS}_B/(b-1)$
Interacción A×B	SS_{AB}	$(a-1)(b-1)$	$\text{MS}_{AB} = \text{SS}_{AB}/[(a-1)(b-1)]$
Error	SS_E	$N-ab$	$\text{MS}_E = \text{SS}_E/(N-ab)$
Total	SS_T	$N-1$	

Table 3: Tabla ANOVA de dos factores

Los estadísticos F para cada hipótesis son:

$$F_A = \frac{\text{MS}_A}{\text{MS}_E} \sim F_{a-1,N-ab}$$
$$F_B = \frac{\text{MS}_B}{\text{MS}_E} \sim F_{b-1,N-ab}$$
$$F_{AB} = \frac{\text{MS}_{AB}}{\text{MS}_E} \sim F_{(a-1)(b-1),N-ab}$$

5 Diseños Experimentales Básicos

Un diseño experimental bien planificado permite obtener conclusiones causales válidas y maximizar la eficiencia del estudio.

5.1 Principios Básicos del Diseño Experimental

1. **Aleatorización:** Asignación aleatoria de tratamientos a unidades experimentales para evitar sesgos
2. **Replicación:** Repetir el experimento para estimar el error experimental y aumentar la precisión
3. **Control local (bloqueo):** Agrupar unidades experimentales homogéneas para reducir variabilidad

5.2 Diseño Completamente Aleatorizado (DCA)

El DCA es el diseño más simple. Los tratamientos se asignan aleatoriamente a todas las unidades experimentales sin restricciones.

Características:

- Máxima flexibilidad en la asignación
- Útil cuando las unidades experimentales son homogéneas
- Modelo: ANOVA de un factor

Ventajas: Análisis sencillo, máximos grados de libertad para el error.
Desventajas: Si hay heterogeneidad no controlada, aumenta el error experimental.

5.3 Diseño en Bloques Completos Aleatorizados (DBCA)

El DBCA agrupa las unidades experimentales en bloques homogéneos. Dentro de cada bloque, los tratamientos se asignan aleatoriamente.

Características:

- Cada bloque contiene todos los tratamientos (una réplica completa)
- Se controla una fuente de variabilidad conocida (bloques)
- Modelo: ANOVA de dos factores sin interacción (bloques como factor)

Modelo estadístico:

$$Y_{ij} = \mu + \tau_i + \beta_j + \varepsilon_{ij} \tag{16}$$

donde τ_i es el efecto del tratamiento i y β_j es el efecto del bloque j.

Ventajas: Reduce el error experimental al controlar variabilidad de bloques.
Cuándo usar: Cuando se puede identificar una fuente clara de variabilidad (ej: lotes de materia prima, días de medición, posición geográfica).

5.4 Diseño en Cuadrado Latino

El Cuadrado Latino controla dos fuentes de variabilidad simultáneamente mediante filas y columnas. Cada tratamiento aparece exactamente una vez en cada fila y una vez en cada columna.

Características:

- Número de tratamientos = número de filas = número de columnas
- Controla dos fuentes de variabilidad
- Modelo: ANOVA de tres factores (tratamientos, filas, columnas) sin interacciones

Ejemplo: Estudio de rendimiento de 4 máquinas, controlando el efecto del operador (filas) y el turno (columnas).

Ventajas: Muy eficiente cuando hay dos fuentes de variabilidad.

Desventajas: Requiere que el número de niveles de todos los factores sea igual; no permite estimar interacciones.

6 ANOVA de Medidas Repetidas

El ANOVA de medidas repetidas se utiliza cuando se mide la misma unidad experimental en múltiples ocasiones (por ejemplo, a lo largo del tiempo).

6.1 Modelo y Supuestos

El modelo básico es:

$$Y_{ij} = \mu + \pi_i + \tau_j + \varepsilon_{ij} \tag{17}$$

donde π_i es el efecto del sujeto i y τ_j es el efecto del tiempo (o condición) j.

Supuesto de esfericidad: Las varianzas de las diferencias entre todos los pares de mediciones repetidas deben ser iguales. Este supuesto es más restrictivo que la homocedasticidad del ANOVA clásico.

6.2 Verificación de Esfericidad

El test de Mauchly evalúa la hipótesis de esfericidad. Si se viola este supuesto, los grados de libertad del estadístico F deben corregirse:

- **Corrección de Greenhouse-Geisser:** Más conservadora, recomendada cuando $\epsilon < 0.75$
- **Corrección de Huynh-Feldt:** Menos conservadora, recomendada cuando $\epsilon > 0.75$

donde ϵ es el estimador de esfericidad.

7 Implementación Computacional

7.1 ANOVA en Python

Python ofrece varias librerías para realizar ANOVA, principalmente `scipy` y `statsmodels`.

7.1.1 ANOVA de un factor con scipy

```python
import numpy as np
from scipy import stats
import pandas as pd

# Datos de ejemplo: tiempo de reaccion (ms) para 3 tratamientos
grupo1 = [23, 25, 27, 29, 24]
grupo2 = [30, 32, 35, 33, 31]
grupo3 = [28, 26, 29, 30, 27]

# ANOVA de un factor
F_stat, p_value = stats.f_oneway(grupo1, grupo2, grupo3)

print(f"Estadistico F: {F_stat:.4f}")
print(f"p-valor: {p_value:.4f}")

if p_value < 0.05:
    print("Rechazamos H0: Al menos una media difiere")
else:
    print("No rechazamos H0: No hay diferencias significativas")
```

Listing 1: ANOVA de un factor en Python

7.1.2 ANOVA con statsmodels y post-hoc

```python
import statsmodels.api as sm
from statsmodels.formula.api import ols
from statsmodels.stats.multicomp import pairwise_tukeyhsd

# Crear DataFrame
data = pd.DataFrame({
    'tiempo': grupo1 + grupo2 + grupo3,
    'tratamiento': ['A']*5 + ['B']*5 + ['C']*5
})

# Ajustar modelo ANOVA
modelo = ols('tiempo ~ C(tratamiento)', data=data).fit()
tabla_anova = sm.stats.anova_lm(modelo, typ=2)

print(tabla_anova)

# Calcular eta cuadrado
ssb = tabla_anova.loc['C(tratamiento)', 'sum_sq']
sst = tabla_anova['sum_sq'].sum()
eta_squared = ssb / sst
print(f"\nEta cuadrado: {eta_squared:.4f}")

# Test post-hoc de Tukey
tukey = pairwise_tukeyhsd(endog=data['tiempo'],
                          groups=data['tratamiento'],
                          alpha=0.05)
print("\nTest de Tukey HSD:")
print(tukey)
```

Listing 2: ANOVA completo con tabla y post-hoc

7.1.3 ANOVA de dos factores

```python
# Datos con dos factores
data2 = pd.DataFrame({
    'rendimiento': [45, 47, 50, 52, 43, 46, 55, 58, 60, 62, 54, 57],
    'fertilizante': ['A', 'A', 'A', 'A', 'B', 'B', 'B', 'B',
                     'C', 'C', 'C', 'C'],
    'riego': ['bajo', 'bajo', 'alto', 'alto', 'bajo', 'bajo',
              'alto', 'alto', 'bajo', 'bajo', 'alto', 'alto']
})

# ANOVA de dos factores con interacci n
modelo2 = ols('rendimiento ~ C(fertilizante) * C(riego)',
              data=data2).fit()
tabla_anova2 = sm.stats.anova_lm(modelo2, typ=2)

print(tabla_anova2)

# Grafico de interacci n
import matplotlib.pyplot as plt
import seaborn as sns

plt.figure(figsize=(8, 5))
sns.pointplot(data=data2, x='fertilizante', y='rendimiento',
              hue='riego', markers=['o', 's'], capsize=0.1)
plt.title('Grafico de Interaccion')
plt.ylabel('Rendimiento')
plt.xlabel('Fertilizante')
plt.legend(title='Riego')
plt.grid(True, alpha=0.3)
plt.tight_layout()
plt.savefig('interaccion.png', dpi=150)
plt.show()
```

Listing 3: ANOVA de dos factores con interacción

7.2 ANOVA en R

R tiene funciones nativas muy potentes para ANOVA, incluyendo `aov()`, `lm()`, y el paquete `car`.

7.2.1 ANOVA de un factor en R

```r
# Crear datos
grupo1 <- c(23, 25, 27, 29, 24)
grupo2 <- c(30, 32, 35, 33, 31)
grupo3 <- c(28, 26, 29, 30, 27)

# Crear data frame
datos <- data.frame(
  tiempo = c(grupo1, grupo2, grupo3),
  tratamiento = factor(rep(c("A", "B", "C"), each = 5))
)

# ANOVA
modelo <- aov(tiempo ~ tratamiento, data = datos)
summary(modelo)
```

```r

# Verificar supuestos
# Normalidad de residuos
shapiro.test(residuals(modelo))

# Homocedasticidad
library(car)
leveneTest(tiempo ~ tratamiento, data = datos)

# Graficos de diagnostico
par(mfrow = c(2, 2))
plot(modelo)

# Test post-hoc de Tukey
TukeyHSD(modelo)
```

Listing 4: ANOVA de un factor en R

7.2.2 ANOVA de dos factores en R

```r
# Datos
datos2 <- data.frame(
  rendimiento = c(45, 47, 50, 52, 43, 46, 55, 58, 60, 62, 54, 57),
  fertilizante = factor(rep(c("A", "B", "C"), each = 4)),
  riego = factor(rep(c("bajo", "alto"), 6))
)

# ANOVA de dos factores con interacci n
modelo2 <- aov(rendimiento ~ fertilizante * riego, data = datos2)
summary(modelo2)

# Grafico de interacci n
interaction.plot(x.factor = datos2$fertilizante,
                 trace.factor = datos2$riego,
                 response = datos2$rendimiento,
                 fun = mean,
                 type = "b",
                 col = c("blue", "red"),
                 pch = c(19, 17),
                 lty = 1,
                 lwd = 2,
                 xlab = "Fertilizante",
                 ylab = "Rendimiento medio",
                 trace.label = "Riego")
```

Listing 5: ANOVA de dos factores en R

7.2.3 Diseño en Bloques Completos Aleatorizados

```r
# Datos de DBCA
datos_dbca <- data.frame(
  produccion = c(50, 55, 58, 48, 53, 60, 52, 57, 62),
  maquina = factor(rep(c("M1", "M2", "M3"), 3)),
  operador = factor(rep(c("Op1", "Op2", "Op3"), each = 3))
)

# ANOVA para DBCA (bloques como factor, sin interacci n)
```

```r
modelo_dbca <- aov(produccion ~ maquina + operador, data = datos_dbca)
summary(modelo_dbca)

# Comparaciones m ltiples para m quinas
TukeyHSD(modelo_dbca, "maquina")
```

Listing 6: DBCA en R

8 Ejercicios Propuestos

8.1 Ejercicio 1: ANOVA de un factor

Un investigador desea comparar la efectividad de cuatro métodos de enseñanza (A, B, C, D) midiendo el puntaje en un examen estandarizado. Los datos son:

- Método A: 78, 82, 79, 85, 80
- Método B: 88, 90, 85, 92, 87
- Método C: 75, 78, 73, 80, 76
- Método D: 82, 84, 86, 83, 85

Tareas:

1. Realizar un ANOVA de un factor ($\alpha = 0.05$)
2. Verificar los supuestos (normalidad, homocedasticidad)
3. Calcular η^2 e interpretar
4. Si hay diferencias significativas, realizar un test post-hoc de Tukey

8.2 Ejercicio 2: ANOVA de dos factores

Un estudio evalúa el efecto de dos factores en el tiempo de secado de pintura:

- Factor A (tipo de pintura): látex, acrílica
- Factor B (temperatura): baja (15°C), media (25°C), alta (35°C)

Se miden tiempos de secado (minutos) con 3 réplicas por combinación de tratamientos.
Tareas:

1. Realizar ANOVA de dos factores
2. Evaluar efectos principales e interacción
3. Graficar el diagrama de interacción e interpretar
4. Si hay interacción significativa, analizar efectos simples

8.3 Ejercicio 3: Diseño en Bloques

Se estudia el rendimiento de 4 variedades de trigo en 5 parcelas (bloques). Cada bloque contiene las 4 variedades asignadas aleatoriamente.

Tareas:

1. Identificar el diseño experimental
2. Realizar el ANOVA correspondiente
3. Comparar con un DCA (ignorando bloques) y comentar diferencias
4. Realizar comparaciones múltiples entre variedades

8.4 Ejercicio 4: Análisis Completo

Datos simulados de un experimento sobre productividad laboral bajo diferentes niveles de ruido (silencio, ruido bajo, ruido moderado, ruido alto).

Tareas:

1. Análisis exploratorio: boxplots, estadísticas descriptivas
2. Verificar supuestos de ANOVA
3. Realizar ANOVA e interpretar resultados
4. Calcular tamaño del efecto
5. Realizar comparaciones post-hoc apropiadas
6. Redactar conclusiones en lenguaje no técnico

9 Conclusiones

El ANOVA es una herramienta fundamental en estadística aplicada que permite comparar medias de múltiples grupos de manera rigurosa. Los conceptos clave incluyen:

- La descomposición de variabilidad en componentes explicados y no explicados
- La importancia de verificar supuestos para validez de las conclusiones
- El uso de comparaciones múltiples post-hoc para identificar diferencias específicas
- La extensión a diseños más complejos (dos factores, medidas repetidas)
- El diseño experimental adecuado como base para inferencias causales válidas

En la práctica, el ANOVA se complementa con visualizaciones efectivas, verificación cuidadosa de supuestos, y reporte transparente de todos los análisis realizados. Las implementaciones en Python y R facilitan estos análisis, permitiendo al analista enfocarse en la interpretación sustantiva de los resultados.

Referencias recomendadas:

- Montgomery, D. C. (2017). *Design and Analysis of Experiments.* Wiley.
- Kutner, M. H., et al. (2005). *Applied Linear Statistical Models.* McGraw-Hill.
- Field, A., Miles, J., & Field, Z. (2012). *Discovering Statistics Using R.* SAGE.