

Unidad 5: Aprendizaje No Supervisado

Bloque 4 – Aprendizaje profundo no supervisado

Métodos de Análisis de Datos I

Departamento de Matemática – Universidad Nacional del Sur

¿Por qué redes neuronales no supervisadas?

Los métodos clásicos (PCA, KDE, K-means) tienen limitaciones cuando la estructura de los datos es **no lineal** y de muy alta dimensión.

¿Qué aportan las redes neuronales?

- Pueden capturar relaciones **no lineales** complejas.
- Escalan a dimensiones muy altas (imágenes, audio, texto).
- Aprenden representaciones jerárquicas de los datos.

Idea clave

El principio fundamental: entrenar la red para que **comprima y reconstruya** los datos. Lo

Autoencoder en este bloque:

Componente	Rol
Encoder	Comprime $x \rightarrow z$
Bottleneck	Representación comprimida
Decoder	Reconstruye $z \rightarrow \hat{x}$

Aplicaciones reales

Compresión de imágenes, detección de anomalías en manufactura, eliminación de ruido en señales médicas, representaciones para NLP, generación de nuevos datos.

Arquitectura del autoencoder

$$x \in \mathbb{R}^p \xrightarrow{\text{encoder}} z \in \mathbb{R}^q \xrightarrow{\text{decoder}} \hat{x} \in \mathbb{R}^p$$

Función de pérdida:

$$\mathcal{L} = \frac{1}{n} \sum_{i=1}^n \|x_i - \hat{x}_i\|^2$$

Entrenamiento: backpropagation estándar. No se necesita ninguna etiqueta y_i .

Arquitectura típica para datos tabulares:

Capa	Detalle
Entrada	p neuronas
Encoder 1	$\text{Dense}(d_1, \text{ReLU}), d_1 < p$

Idea clave

Un autoencoder es como un sistema de mensajería con canal angosto: el encoder resume la novela en un telegrama (z) y el decoder reconstruye la novela desde el telegrama. Si el canal es angosto, la red aprende qué es lo más importante.

Aplicaciones reales

Imágenes: el bottleneck de un autoencoder entrenado en rostros

Autoencoder como reductor de dimensionalidad

El vector latente z es una representación de x en q dimensiones.

Comparación con PCA:

	PCA	Autoencoder
Transformación	Lineal	No lineal
Computación	Analítica (SVD)	Iterativa (GD)
Interpretación	Alta (loadings)	Baja
Escala	Alta	Alta

Idea clave

Un autoencoder **lineal** (sin activaciones no lineales) de una sola capa oculta es matemáticamente equivalente a PCA. Las

Aplicaciones reales

Genómica: reducir perfiles de expresión de 20.000 genes a 10–30 dimensiones latentes, capturando relaciones no lineales entre genes que PCA no ve.

Sensores industriales: comprimir señales de vibración de 500 canales simultáneos a 5 dimensiones latentes para monitoreo en tiempo real.

Astronomía: representar espectros de galaxias en pocas dimensiones para clasificación y búsqueda de objetos

Autoencoder para detección de anomalías

Principio: entrenar el autoencoder **solo con datos normales**.

Un autoencoder bien entrenado en datos normales:

- Reconstruye bien los datos normales:
 $\|x - \hat{x}\|^2$ pequeño.
- Reconstruye mal las anomalías: el modelo no “aprendió” ese patrón.

Score de anomalía:

$$\text{score}(x) = \|x - \hat{x}\|^2$$

Se fija un umbral τ : si $\text{score}(x) > \tau \Rightarrow$ anomalía.

Aplicaciones reales

Manufactura: entrenar con imágenes de piezas sin defectos. Las piezas con grietas o deformaciones tienen error de reconstrucción alto.

Fraude bancario: entrenar con transacciones legítimas. Las transacciones fraudulentas tienen patrones no vistos que el autoencoder no puede reconstruir bien.

Cardiología: entrenar con ECGs (electrocardiogramas) normales. Arritmias raras generan error de

Denoising autoencoders

Idea: corromper los datos de entrada con ruido y entrenar para reconstruir la versión limpia.

$$\tilde{x} = x + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2 I)$$

Pérdida:

$$\mathcal{L} = \frac{1}{n} \sum_{i=1}^n \|x_i - \text{decoder}(\text{encoder}(\tilde{x}_i))\|^2$$

Idea clave

Al forzar al encoder a ignorar el ruido y capturar solo la estructura real, el autoencoder aprende representaciones más

Aplicaciones reales

Imágenes médicas: eliminar ruido en imágenes de tomografía (CT) o resonancia magnética (MRI) adquiridas con dosis bajas de radiación.

Audio: separar la voz del ruido de fondo en grabaciones con micrófono de baja calidad.

Astronomía: recuperar señales débiles de galaxias lejanas contaminadas por ruido instrumental.

Texto: corregir errores tipográficos o

Dimensión del bottleneck:

- Demasiado pequeña: pierde información, reconstrucción pobre.
- Demasiado grande: puede memorizar en lugar de generalizar.
- Explorar con validación cruzada o curva de reconstrucción.

Regularización:

- Dropout en encoder y decoder.
- Regularización L2 en los pesos.
- Denoising (ruido en la entrada).

Preprocesamiento:

- Escalar a $[0, 1]$ si la salida es sigmoid

Atención

El umbral de anomalía τ es crítico y depende del dominio. Definirlo mirando la distribución de errores de reconstrucción en el conjunto de entrenamiento (por ejemplo, percentil 95 o 99).

Aplicaciones reales

CARDIO-PLACA (ejemplo propio): entrenar un autoencoder con los 25 predictores clínicos de pacientes sanos.

Autoencoders en síntesis:

Uso	Mecanismo
Reducción de dim.	Vector latente z
Detección anomalías	Error de reconstrucción
Eliminación de ruido	Denoising autoencoder

Vs. métodos clásicos:

- Más potente que PCA para estructuras no lineales.
- Más costoso computacionalmente.
- Menos interpretable.
- Requiere más datos para entrenar bien.

Cierre de la Unidad 5 – los 4 bloques:

Bloque	Pregunta central
Clustering	¿Hay grupos naturales?
Representación	¿Puedo ver los datos en men
Densidad/anomalías	¿Hay puntos raros?
Autoencoders	¿Puedo comprimir y reconstr

Hilo conductor: los cuatro bloques trabajan sin etiquetas y_i . La estructura emerge de los datos mismos. La elección del método depende de la pregunta que uno quiere responder.