

Unidad 5: Aprendizaje No Supervisado

Bloque 1 – Clustering

Métodos de Análisis de Datos I

Departamento de Matemática – Universidad Nacional del Sur

¿Qué es el clustering?

Problema: dado un conjunto de observaciones $\{x_1, \dots, x_n\}$ *sin etiquetas*, encontrar grupos homogéneos.

Idea clave

Los puntos dentro de un grupo deben ser **similares entre sí** y **distintos** de los de otros grupos. Nadie nos dice cuáles son los grupos: emergen de los datos.

Diferencia con clasificación:

- Clasificación: tenemos y_i , aprendemos $f(x) \rightarrow y$.
- Clustering: no hay y_i ; la estructura la

Comparativa de métodos:

Método	Requiere k	Outliers
K-means	Sí	Sensible
Jerárquico	No*	Sensible
DBSCAN	No	Detecta
GMM	Sí	Moderado

*elige k al cortar el dendrograma

Aplicaciones reales

Segmentación de clientes,
agrupamiento de genes, detección
de tópicos, compresión de imágenes.

Métricas de distancia

Todo algoritmo de clustering necesita medir “similitud”. La elección importa.

Distancia Euclidiana

$$d_E(x, z) = \sqrt{\sum_{j=1}^p (x_j - z_j)^2}$$

La más usada. Sensible a escala.

Distancia Manhattan

$$d_M(x, z) = \sum_{j=1}^p |x_j - z_j|$$

Más robusta a outliers.

Distancia Coseno

$$d_{\cos}(x, z) = 1 - \frac{x \cdot z}{\|x\| \|z\|}$$

Ideal para texto: importa la dirección, no la magnitud.

Atención

Siempre escalar antes de clusterizar.
Si una variable es salario en pesos y otra es edad en años, la primera domina la distancia sin razón conceptual.

K-means: algoritmo

Objetivo: minimizar la inercia (varianza intra-cluster):

$$W = \sum_{l=1}^k \sum_{x_i \in C_l} \|x_i - \mu_l\|^2$$

Algoritmo:

- 1 Inicializar k centroides.
- 2 **Asignar** cada punto al centroide más cercano.
- 3 **Actualizar** cada centroide como la media de su cluster.
- 4 Repetir hasta convergencia.

Aplicaciones reales

Marketing: segmentar clientes por comportamiento de compra para campañas dirigidas.

Medicina: agrupar pacientes con perfiles clínicos similares para tratamientos personalizados.

Imágenes: cuantización de color: reducir una imagen de millones de colores a k colores representativos (compresión).

Astronomía: clasificar galaxias por forma y brillo en catálogos de millones

K-means: ¿cuántos clusters?

Método del codo:

Graficar inercia W vs. k . Buscar el punto donde la reducción se aplana.

$k = 1 \rightarrow k = 2$: gran caída

$k = 5 \rightarrow k = 6$: caída mínima $\Rightarrow k = 5$

Coeficiente de silueta para cada punto i :

$$s_i = \frac{b_i - a_i}{\max(a_i, b_i)} \in [-1, 1]$$

a_i : distancia media a su cluster.

b_i : distancia media mínima a otro cluster.

$\bar{s}$ cerca de 1: clusters bien separados.

Aplicaciones reales

Retail: un supermercado analiza tickets de compra. Con $k = 3$ emerge: “compradores semanales de grandes volúmenes”, “compradores diarios de poco”, “compradores de ocasión”. La curva del codo confirma $k = 3$.

Recursos humanos: agrupar empleados por desempeño y antigüedad. La silueta indica si los grupos son realmente distintos o si se solapan.

Clustering jerárquico

Idea: construir una jerarquía de fusiones.

Algoritmo aglomerativo:

- 1 Cada punto es su propio cluster.
- 2 Fusionar los dos clusters más cercanos.
- 3 Repetir hasta un único cluster.

Métodos de enlace:

Enlace	Distancia entre A y B
Simple	mínima entre pares
Completo	máxima entre pares
Promedio	media de todas las distancias
Ward	minimiza aumento de inercia

Idea clave

Aplicaciones reales

Genómica: agrupar genes con patrones de expresión similares en experimentos de microarray. El dendrograma revela familias de genes que se activan juntos.

Lingüística: construir familias de lenguas por similitud léxica. El árbol resultante coincide con clasificaciones históricas (romance, germánicas, eslavas).

Arqueología: clasificar artefactos por composición química para inferir rutas de comercio.

DBSCAN: clustering por densidad

Parámetros: radio ε y mínimo de vecinos m .

Tipos de puntos:

- **Núcleo:** tiene $\geq m$ vecinos en radio ε .
- **Borde:** está en la vecindad de un núcleo.
- **Ruido:** ni núcleo ni borde.

Los puntos núcleo conectados forman un cluster.

Idea clave

DBSCAN no requiere especificar k y puede encontrar clusters de **cualquier forma**. Los outliers quedan etiquetados explícitamente como ruido.

Aplicaciones reales

Geolocalización: detectar zonas de alta concentración de accidentes de tráfico en una ciudad. La forma irregular de las zonas peligrosas no es capturada por K-means.

Astronomía: identificar cúmulos de estrellas en mapas del cielo. Las galaxias tienen formas filamentosas, no esféricas.

Detección de fraude: transacciones bancarias inusuales aparecen como ruido (outliers) rodeadas de clusters de

Modelos de Mezclas Gaussianas (GMM)

Modelo: los datos provienen de k gaussianas:

$$p(x) = \sum_{l=1}^k \pi_l \mathcal{N}(x \mid \mu_l, \Sigma_l)$$

Estimación por EM:

- ➊ **Paso E:** calcular probabilidad de pertenencia r_{il} a cada componente.
- ➋ **Paso M:** actualizar π_l , μ_l , Σ_l .
- ➌ Repetir hasta convergencia.

Idea clave

A diferencia de K-means, la asignación es blanda: cada punto tiene probabilidad r_{il} de

Aplicaciones reales

Reconocimiento de voz: modelar fonemas como mezclas de gaussianas en el espacio de características acústicas.

Biometría: modelar distribuciones de huellas dactilares o iris para sistemas de identificación.

Finanzas: modelar retornos financieros con régimen mixto: un componente de “días normales” y otro de “crisis” (alta volatilidad).

Medicina: en imágenes de resonancia magnética, segmentar tejidos (matrices

Evaluación de clustering

Sin etiquetas verdaderas, la evaluación es **intrínseca**.

Coefficiente de silueta $\bar{s} \in [-1, 1]$

Para cada punto i :

$$s_i = \frac{b_i - a_i}{\max(a_i, b_i)}$$

a_i : distancia media dentro del cluster.

b_i : distancia media mínima al cluster más cercano.

Davies-Bouldin (menor es mejor):

$$DB = \frac{1}{k} \sum_l \max_{j \neq l} \frac{s_l + s_j}{d(\mu_l, \mu_j)}$$

Calinski-Harabasz (mayor es mejor):

Idea clave

No existe una única métrica “correcta”. Lo ideal es usar varias y combinarlas con el criterio del dominio.

Aplicaciones reales

Salud: al segmentar pacientes, la silueta indica si los grupos son clínicamente distinguibles. Si $\bar{s} < 0.3$, los grupos se solapan y quizás el número de clusters es incorrecto.

Resumen: Bloque 1 – Clustering

Método	Criterio	Forma	Outliers	Cuándo usarlo
K-means	Inercia mínima	Esférica	Sensible	Clusters bien separados, k conocido
Jerárquico	Enlace entre grupos	Flexible	Sensible	Quiero explorar la jerarquía
DBSCAN	Densidad local	Arbitraria	Detecta	Forma irregular, outliers presentes
GMM	Verosimilitud	Elíptica	Moderado	Necesito probabilidades de pertenencia

Regla práctica:

- Empezar siempre con K-means para tener una línea de base.
- Si los datos tienen ruido o forma irregular → DBSCAN.
- Si quiero jerarquía o no sé k → jerárquico.

Pipeline típico:

- 1 Escalar variables.
- 2 Explorar con K-means + codo + silueta.
- 3 Refinar con DBSCAN o jerárquico si es necesario.
- 4 Evaluar con múltiples métricas + criterio de dominio.