

Unidad 5: Aprendizaje No Supervisado

Bloque 3 – Densidad y anomalías

Métodos de Análisis de Datos I

Departamento de Matemática – Universidad Nacional del Sur

¿Qué es una anomalía?

Una **anomalía** (outlier) es una observación que no se ajusta al patrón general de los datos.

Idea clave

Un punto es anómalo si vive en una región de **baja densidad**: está donde los datos son escasos. Los métodos de este bloque difieren en cómo estiman o explotan esa densidad.

Tipos de anomalías:

- **Global**: anómalo respecto a todo el dataset.
- **Contextual**: normal globalmente, anómalo en su vecindad (LOF).
- **Colectivo**: un grupo de puntos es anómalo en

Métodos de este bloque:

Método	Enfoque	Contexto
KDE	Densidad global	No
Isolation Forest	Aislamiento	No
LOF	Densidad local	Sí
One-Class SVM	Frontera	Parcial

Aplicaciones reales

Fraude financiero, fallas industriales, intrusión en redes, control de calidad, vigilancia médica, errores de sensores.

KDE: Estimación de Densidad por Núcleo

Idea: estimar $f(x)$ sin asumir ninguna forma paramétrica.

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right)$$

Cada observación “aporta” una campana centrada en sí misma. La suma es la densidad estimada.

Kernels comunes:

Gaussiano	$(2\pi)^{-1/2} \exp(-u^2/2)$
Epanechnikov	$\frac{3}{4}(1 - u^2)1_{ u \leq 1}$

Ancho de banda h : controla el suavizado.

- h grande: curva suave, puede ocultar estructura.

Idea clave

El histograma apila bloques en bins fijos. KDE reemplaza cada bloque por una campana centrada en cada dato. El resultado es una curva suave que no depende de la posición arbitraria de los bins.

Aplicaciones reales

Epidemiología: estimar la distribución geográfica de casos de una enfermedad sin asumir que sigue una forma paramétrica conocida.

Isolation Forest

Principio: los outliers son más fáciles de aislar que los puntos normales.

Construcción:

- 1 Construir múltiples **árboles de aislamiento**: en cada árbol, elegir aleatoriamente una variable y un corte aleatorio para dividir el espacio.
- 2 Repetir hasta aislar cada punto.

Score de anomalía: inversamente proporcional a la longitud media del camino de raíz a hoja, promediada sobre todos los árboles.

Idea clave

Ventajas:

- Escala bien a datos grandes.
- No requiere calcular distancias.
- Robusto en alta dimensionalidad.

Parámetros: `contamination` (fracción esperada de outliers), `n_estimators`.

Aplicaciones reales

Banca: detectar transacciones fraudulentas en tiempo real entre millones de operaciones diarias.

Manufactura: sensores en líneas de producción generan millones de

LOF: Local Outlier Factor

LOF compara la **densidad local** de un punto con la de sus vecinos.

$$LOF_k(x_i) = \frac{\overline{lrd}_k(N_k(x_i))}{lrd_k(x_i)}$$

$lrd_k(x_i)$: densidad de alcanzabilidad local de x_i .
 $\overline{lrd}_k$: promedio de densidades de sus k vecinos.

- $LOF \approx 1$: densidad similar a vecinos $\rightarrow$ normal.
- $LOF \gg 1$: densidad mucho menor que vecinos $\rightarrow$ outlier.

Idea clave

Atención

LOF requiere calcular distancias a todos los vecinos: escala mal a datasets muy grandes. Para millones de puntos, preferir Isolation Forest.

Aplicaciones reales

Sensores ambientales: una estación meteorológica en un valle puede tener temperaturas “normales” globalmente pero anómalas respecto a sus vecinas geográficas.

One-Class SVM

One-Class SVM aprende una **frontera de decisión** que encierra la mayor parte de los datos de entrenamiento.

Idea: encontrar un hiperplano en el espacio de características (via kernel) que separe los datos del origen con margen máximo.

Observaciones fuera de la frontera → anomalías.

Idea clave

A diferencia de Isolation Forest y LOF, One-Class SVM aprende una **frontera explícita** en el espacio de entrada. El kernel permite que esa frontera sea no lineal.

Atención

One-Class SVM es sensible a la escala y requiere ajuste cuidadoso del kernel. Escala mal a datasets muy grandes (costo cuadrático en n). Mejor para datasets pequeños o medianos con buena caracterización del “comportamiento normal”.

Aplicaciones reales

Detección de intrusiones: entrenar solo con tráfico de red legítimo;

Resumen: Bloque 3 – Densidad y anomalías

Método	Principio	Escala	Contextual	Cuándo usarlo
KDE	Estima $f(x)$	Moderada	No	Exploración, visualización de densidad
Isolation Forest	Aislamiento	Alta	No	Datos grandes, score global
LOF	Densidad local	Moderada	Sí	Outliers contextuales
One-Class SVM	Frontera (kernel)	Baja	Parcial	Datasets pequeños, frontera explícita

Regla práctica:

- Para exploración y visualización → **KDE**.
- Para datos grandes en producción → **Isolation Forest**.
- Si los outliers son contextuales → **LOF**.
- Si tengo pocos datos y quiero frontera

Kernel + One-Class SVM

Buenas prácticas:

- Siempre escalar antes de aplicar cualquier método.
- Combinar múltiples detectores y tomar el consenso.
- Definir contamination según el dominio (¿cuánto fraude espero?)