

Unidad 5: Aprendizaje No Supervisado

Bloque 2 – Representación de datos

Métodos de Análisis de Datos I

Departamento de Matemática – Universidad Nacional del Sur

¿Por qué reducir dimensionalidad?

Los datos modernos son de alta dimensión: imágenes ($p > 10^6$), genómica ($p > 20,000$), texto ($p > 100,000$). Esto genera problemas:

- **Maldición de la dimensionalidad:** en dimensiones altas, todos los puntos quedan “lejos” entre sí.
- **Visualización imposible:** no podemos ver más de 3 dimensiones.
- **Modelos inestables:** muchas variables correlacionadas generan colinealidad.

Idea clave

Los métodos de reducción buscan una función $f : \mathbb{R}^p \rightarrow \mathbb{R}^q$ con $q \ll p$ que preserve la estructura

Comparativa de métodos:

Método	Tipo	Supervisado
PCA	Lineal	No
t-SNE	No lineal	No
UMAP	No lineal	No
LDA	Lineal	Sí

Aplicaciones reales

Visualización de datos genómicos, compresión de imágenes, preprocesamiento para clasificadores, exploración de corpus de texto.

PCA: Análisis de Componentes Principales

Objetivo: encontrar proyecciones lineales que maximizan la varianza.

Sea S la matriz de covarianza muestral. PCA resuelve:

$$v_1 = \arg \max_{\|v\|=1} v^T S v$$

La solución es el autovector de S de mayor autovalor.

Varianza explicada por componente j :

$$\frac{\lambda_j}{\sum_{l=1}^p \lambda_l}$$

Idea clave

Aplicaciones reales

Genómica: reducir 20.000 genes a 10–20 componentes en estudios de expresión génica. Las primeras PCs separan tipos celulares o condiciones experimentales.

Neurociencia: analizar señales de cientos de electrodos simultáneos. PCA extrae los “modos” de activación neuronal predominantes.

Climatología: reducir datos de temperatura de miles de estaciones meteorológicas. La primera PC suele

PCA: selección de componentes e interpretación

¿Cuántas componentes retener?

Varianza acumulada: elegir q tal que

$$\sum_{j=1}^q \lambda_j / \sum \lambda_l \geq 0.90.$$

Scree plot: graficar λ_j vs. j . Cortar en el codo.

Regla de Kaiser: retener solo $\lambda_j > 1$
(variables estandarizadas).

Interpretación:

- **Loadings** v_{jl} : peso de la variable l en la componente j .
- **Scores** z_{ij} : coordenada de la observación i en la componente j .
- **Biplot:** superpone scores y loadings en un gráfico.

Atención

PCA es sensible a la escala. **Siempre estandarizar** antes de aplicarlo, salvo que todas las variables estén en la misma unidad y se quiera preservar diferencias de varianza.

Aplicaciones reales

Psicología: en tests de inteligencia con 50 ítems, la primera PC suele ser el “factor g ” (inteligencia general), que explica el 30–40% de la varianza.

t-SNE: visualización no lineal

Idea: preservar la estructura **local** de los datos en 2D.

- 1 Modelar similitudes en alta dimensión con gaussianas (p_{ij}).
- 2 Modelar similitudes en 2D con distribución t de Student (q_{ij}) — colas pesadas para evitar colapso.
- 3 Minimizar divergencia KL entre ambas distribuciones.

Parámetro clave: perplejidad (5–50), controla cuántos vecinos se consideran “ceranos”.

Atención

Aplicaciones reales

Inmunología: visualizar millones de células en experimentos de citometría de flujo. t-SNE revela subpoblaciones de linfocitos no distinguibles a simple vista.

NLP: visualizar embeddings de palabras (Word2Vec, BERT). Palabras semánticamente similares forman clusters visibles en 2D.

Dígitos escritos a mano: el dataset MNIST (70.000 imágenes de dígitos 0–9) forma 10 clusters bien separados en el mapa t-SNE.

UMAP: alternativa moderna a t-SNE

UMAP (Uniform Manifold Approximation and Projection) está basado en geometría diferencial y topología algebraica.

Ventajas sobre t-SNE:

- Más rápido (escala a millones de puntos).
- Preserva mejor la **estructura global**, no solo local.
- Determinístico con semilla fija.
- Funciona para $q > 2$ dimensiones.
- Permite proyectar nuevas observaciones.

Parámetros:

- `n_neighbors`: balance local/global (típico: 15).

Aplicaciones reales

Biología celular: UMAP es el estándar de facto para visualizar datos de secuenciación de ARN de célula única (scRNA-seq). Mapas de decenas de miles de células revelan trayectorias de diferenciación celular.

Astronomía: el relevamiento Gaia de mil millones de estrellas usa UMAP para explorar relaciones entre parámetros estelares.

Ciberseguridad: visualizar tráfico de red para detectar patrones anómalos en

LDA: reducción supervisada

LDA (Linear Discriminant Analysis) maximiza la separabilidad entre clases **conocidas**.

Criterio de Fisher:

$$J(w) = \frac{w^T S_B w}{w^T S_W w}$$

S_B : dispersión **entre** clases.

S_W : dispersión **dentro** de clases.

La solución son los autovectores de $S_W^{-1} S_B$.

Con k clases: hasta $\min(k - 1, p)$ dimensiones.

Idea clave

PCA busca la dirección de mayor varianza total. LDA busca la dirección que mejor

Atención

LDA es **supervisado**: requiere etiquetas de clase. Es útil como exploración (¿son las clases linealmente separables?) y como preprocesamiento antes de un clasificador.

Aplicaciones reales

Medicina: reducir decenas de biomarcadores a 1–2 ejes discriminantes entre “sano”, “pre-enfermo” y “enfermo”.

Reconocimiento facial: Fisherfaces –

Resumen: Bloque 2 – Representación de datos

Método	Transformación	Estructura	Sup.	Uso típico
PCA	Lineal	Global (varianza)	No	Preprocesamiento, exploración
t-SNE	No lineal	Local	No	Visualización 2D
UMAP	No lineal	Local + global	No	Visualización, preprocesamiento
LDA	Lineal	Separabilidad	Sí	Exploración supervisada, clasificación

Regla práctica:

- Para preprocesamiento y comprensión → **PCA**.
- Para visualización exploratoria → **UMAP** (o t-SNE).
- Si tengo etiquetas y quiero ver separabilidad → **LDA**.

Pipeline típico:

- 1 Estandarizar variables.
- 2 PCA para reducir dimensión y eliminar colinealidad.
- 3 UMAP para visualización del espacio reducido.
- 4 LDA si hay clases y quiero ver su