

Métodos de Análisis de Datos I

Unidad 6 – Bloque 2: Inteligencia Artificial Explicable (XAI)

Departamento de Matemática – UNS

2026

El problema de la caja negra

Un modelo entrenado puede predecir con alta precisión... pero ¿por qué tomó esa decisión?

Casos donde importa explicar:

- Crédito bancario denegado
- Diagnóstico médico asistido
- Contratación de personal
- Sentencias judiciales asistidas
- **Rendimiento deportivo**

El dilema

Los modelos más precisos (redes neuronales, XGBoost, random forests) suelen ser los menos interpretables.

Los más interpretables (regresión lineal, árbol pequeño) suelen ser los menos precisos.

Definición

XAI (eXplainable Artificial Intelligence) es el conjunto de técnicas que permiten entender, interpretar y justificar las predicciones de modelos de ML, especialmente los de alta complejidad.

Dos grandes dimensiones:

- **Global vs. local:** ¿explicamos el comportamiento general del modelo o una predicción particular?
- **Intrínseca vs. post-hoc:** ¿el modelo es interpretable por diseño, o aplicamos XAI después de entrenarlo?

Intrínsecas (modelo interpretable):

- Regresión lineal/logística
- Árbol de decisión (profundidad baja)
- Reglas de decisión

Post-hoc globales:

- Importancia de variables (permutación)
- PDP / ICE
- SHAP (valores globales)

Post-hoc locales:

- LIME
- SHAP (valores individuales)
- Contrafácticos

En este bloque

Trabajamos con **importancia por permutación, PDP/ICE, SHAP y LIME**, aplicados a un dataset de rendimiento de jugadores de fútbol.

El dataset de trabajo

Problema: predecir si un jugador será convocado a la selección nacional (variable binaria: 1 = convocado, 0 = no convocado).

Variables predictoras:

- goles: goles en el torneo
- asistencias: asistencias de gol
- minutos: minutos jugados
- pases_clave: pases que generan tiro
- duelos_ganados: % duelos ganados
- velocidad: máxima en km/h
- faltas_recibidas: por partido
- edad: años
- valor_mercado: millones de euros
- posicion: numérica (1–4)

Modelo utilizado: **Random Forest** (clasificador).

Importancia de variables por permutación

Idea

Para cada variable X_j : permutar aleatoriamente sus valores en el conjunto de validación y medir cuánto cae el rendimiento del modelo. Si cae mucho $\Rightarrow$ la variable era importante.

Ventajas sobre la importancia por impureza (Gini):

- No favorece artificialmente variables con muchas categorías.
- Se evalúa en datos de validación, no de entrenamiento.
- Agnóstica al modelo: funciona con cualquier algoritmo.

Limitación

Si dos variables están correlacionadas, la importancia de ambas puede subestimarse al permutar una sola.

Gráfico de dependencia parcial (PDP)

Definición

El **PDP** (Partial Dependence Plot) muestra el efecto **promedio** de una variable X_j sobre la predicción, marginalizando sobre el resto de variables.

Construcción:

- 1 Fijar un valor x_j^* para la variable de interés.
- 2 Reemplazar X_j con x_j^* en **todos** los ejemplos.
- 3 Calcular la predicción promedio del modelo.
- 4 Repetir para distintos valores de x_j^* .

Ejemplo: ¿Cómo varía la probabilidad de convocatoria en función de los goles marcados, promediando sobre todos los jugadores?

Definición

Las curvas **ICE** (Individual Conditional Expectation) muestran el efecto de X_j sobre la predicción para **cada observación individualmente**.

PDP: una curva, efecto promedio.

ICE: una curva por observación.

El PDP es el promedio de las curvas ICE.

¿Cuándo importa la diferencia?

Cuando hay **interacciones**: el efecto de X_j depende del valor de otras variables. El PDP oculta esa heterogeneidad.

Ejemplo

Para goles vs. convocatoria:

Jugadores defensores pueden mostrar una curva ICE plana (los goles no les cambian la chance), mientras que delanteros muestran una curva fuertemente creciente.

El PDP promedia ambas y puede malinterpretar el efecto.

SHAP: valores de Shapley para ML

Origen

Los **valores de Shapley** provienen de la teoría de juegos cooperativos (Lloyd Shapley, 1953). La idea: distribuir el “pago” (predicción) entre los “jugadores” (variables) de forma justa.

Interpretación para ML:

El valor SHAP de la variable X_j para una observación i es la **contribución marginal promedio** de esa variable a la predicción, considerando todas las posibles coaliciones de variables.

Propiedad clave

$$\hat{f}(x_i) = \phi_0 + \sum_{j=1}^p \phi_j^{(i)}$$

La predicción se descompone exactamente como suma de contribuciones individuales.

SHAP: tipos de visualización

Beeswarm (enjambre):

- Un punto por observación.
- Eje x: valor SHAP (contribución).
- Color: valor de la variable (alto/bajo).
- Muestra distribución de efectos.

Importancia global:

- $|\phi_j|$ promedio sobre todas las observaciones.
- Ranking de variables.

Waterfall (cascada):

- Una observación específica.
- Muestra paso a paso cómo cada variable sube o baja la predicción desde el valor base ϕ_0 .
- Ideal para explicar **una decisión puntual**.

Ejemplo

Jugador i : goles $\uparrow$ SHAP= +0.18, edad $\downarrow$ SHAP= -0.09, velocidad $\uparrow$ SHAP= +0.12...

SHAP: propiedades axiomáticas

Los valores SHAP son los **únicos** que satisfacen simultáneamente:

- ❶ **Eficiencia:** las contribuciones suman exactamente la predicción menos el valor base.
- ❷ **Simetría:** si dos variables contribuyen igual en todas las coaliciones, reciben el mismo valor.
- ❸ **Variable ficticia:** si una variable no cambia ninguna predicción, su SHAP es cero.
- ❹ **Aditividad:** para modelos combinados, los SHAPs se suman.

Costo computacional

Calcular los valores exactos requiere 2^P coaliciones. En la práctica se usan aproximaciones eficientes (TreeSHAP para árboles, KernelSHAP para modelos generales).

Definición

LIME (Local Interpretable Model-agnostic Explanations) aproxima el modelo complejo **localmente** alrededor de una observación de interés, usando un modelo simple e interpretable.

Procedimiento:

- 1 Tomar la observación x_i a explicar.
- 2 Generar perturbaciones de x_i (vecindad local).
- 3 Obtener las predicciones del modelo original para esas perturbaciones.
- 4 Ajustar un modelo simple (regresión lineal regularizada) pesando las perturbaciones por su cercanía a x_i .
- 5 Los coeficientes del modelo simple son la explicación.

LIME:

- Explicación local aproximada.
- Modelo simple ajustado localmente.
- Puede ser inestable: pequeños cambios en x_i pueden cambiar la explicación.
- Agnóstico al modelo.
- Más intuitivo para no expertos.

SHAP:

- Explicación local exacta (con aproximaciones eficientes).
- Fundamentación teórica sólida (teoría de juegos).
- Consistente y estable.
- Versiones optimizadas para tipos de modelos (TreeSHAP).
- Más costoso computacionalmente.

En la práctica: **SHAP** para análisis riguroso; **LIME** para comunicar a audiencias no técnicas o explorar rápidamente.

Explicaciones contrafácticas

Definición

Una **explicación contrafáctica** responde: ¿qué mínimo cambio en las variables de entrada habría llevado a una predicción diferente?

Ejemplo

Jugador i no fue convocado. El modelo indica:

“Si hubiera tenido 2 goles más y 10 minutos más por partido, habría sido convocado.”

Ventajas:

- Muy accionables: dicen *qué cambiar*, no solo *qué importó*.
- No requieren revelar el modelo completo.
- Familiares para los usuarios (razonamiento humano natural).

Desafío: pueden existir muchos contrafácticos válidos. ¿Cuál elegir?

- 1 XAI no es un lujo: en muchos contextos es un **requisito ético y regulatorio**.
- 2 **Global vs. local**: entender el modelo en general o explicar una decisión puntual son preguntas distintas que requieren herramientas distintas.
- 3 **PDP/ICE** muestran el efecto marginal de una variable; ICE revela heterogeneidad que el PDP oculta.
- 4 **SHAP** descompone la predicción en contribuciones individuales con garantías teóricas.
- 5 **LIME** aproxima localmente con un modelo simple; útil para comunicar pero menos estable.
- 6 Los **contrafácticos** son la forma más accionable de explicar una decisión.
- 7 Ninguna técnica reemplaza el juicio: la explicación debe interpretarse en contexto.