

Métodos de Análisis de Datos I

Unidad 6 – Bloque 4: El data scientist en contexto

Departamento de Matemática – UNS

2026

Contenidos

- 1 Más allá del modelo
- 2 Ética y sesgo en los datos
- 3 Cuándo NO usar ML
- 4 Limitaciones del modelo vs. limitaciones del dato
- 5 El rol del analista como traductor
- 6 El ciclo de vida de un proyecto de datos
- 7 Cierre

El trabajo real de un analista de datos

En los cursos aprendemos a construir modelos. En el trabajo real, construir el modelo es solo una parte.

Lo que se enseña:

- Preprocesamiento
- Selección de modelo
- Entrenamiento y evaluación
- Métricas

Lo que también ocupa tiempo real:

- Entender el problema de negocio
- Conseguir y limpiar los datos
- Negociar qué pregunta es responsable
- Comunicar resultados
- Mantener y monitorear modelos en producción

Estimación práctica

En proyectos reales, entre el 60% y el 80% del tiempo se gasta en datos: obtenerlos, entenderlos, limpiarlos, validarlos. El modelado ocupa una fracción menor de lo que se imagina.

Sesgo: el problema empieza en los datos

Un modelo aprende de los datos. Si los datos tienen sesgos, el modelo los amplifica.

Tipos de sesgo frecuentes:

- **Sesgo de selección:** los datos no representan a la población objetivo.
Ejemplo: un modelo de crédito entrenado solo con clientes que accedieron al crédito, sin incluir a los rechazados.
- **Sesgo histórico:** los datos reflejan decisiones pasadas injustas.
Ejemplo: contratación histórica con discriminación de género → modelo que perpetúa esa discriminación.
- **Sesgo de medición:** el instrumento que genera los datos no mide lo mismo para todos los grupos.
Ejemplo: detección de enfermedades con herramientas calibradas para un solo grupo demográfico.

COMPAS (2016):

Sistema de predicción de reincidencia criminal usado en EE.UU.

Un análisis periodístico mostró que asignaba puntuaciones de riesgo más altas a acusados afroamericanos que a blancos con perfiles similares.

Amazon Recruiting (2018):

Amazon descartó un sistema de selección de CVs porque penalizaba sistemáticamente a mujeres, habiendo aprendido de contrataciones históricas dominadas por hombres.

Reconocimiento facial:

Estudios (MIT Media Lab, 2018) mostraron que sistemas comerciales tenían tasas de error hasta 34 puntos porcentuales más altas para mujeres de piel oscura que para hombres de piel clara.

La lección

La objetividad del algoritmo es una ilusión si los datos de entrenamiento codifican injusticia histórica.

Equidad algorítmica: no hay una sola definición

Intuitivamente, un modelo “justo” trata igual a todos. Formalmente, hay varias definiciones incompatibles entre sí:

- **Paridad demográfica:** igual tasa de positivos en todos los grupos.
- **Igualdad de oportunidades:** igual tasa de verdaderos positivos (TPR) entre grupos.
- **Calibración:** igual significado de la puntuación de riesgo entre grupos.

Resultado teórico (Chouldechova, 2017)

Cuando las tasas base de la variable objetivo difieren entre grupos, **no es posible** satisfacer simultáneamente paridad demográfica, igualdad de oportunidades y calibración.
Elegir una definición de equidad implica sacrificar otra.

Cuándo NO usar machine learning

ML no es la solución a todo. Hay situaciones donde **no corresponde** o **no ayuda**.

No usar ML cuando:

- El problema se resuelve con una regla simple y conocida.
- No hay suficientes datos.
- El proceso subyacente cambia tan rápido que cualquier modelo queda desactualizado.
- La explicabilidad es un requisito no negociable y el modelo no la provee.
- El costo de un error es muy alto y no hay forma de auditarlo.

Ejemplo

Una empresa quiere predecir si un cliente pagará a tiempo.
Tiene 80 registros históricos.

Un modelo de ML no tiene suficientes datos para generalizar. Una regla heurística (“clientes con más de 3 atrasos previos → riesgo alto”) puede ser más robusta y explicable.

La maldición de la complejidad innecesaria

Más complejo $\neq$ mejor.

Principio de parsimonia:

Entre dos modelos con rendimiento similar, preferir el más simple. Razones:

- Más fácil de interpretar y auditar.
- Menos propenso a sobreajuste en datos pequeños.
- Más fácil de mantener en producción.
- Menos costoso computacionalmente.
- Más fácil de explicar a quienes toman decisiones.

Regla práctica

Antes de usar XGBoost o una red neuronal, probar regresión logística o un árbol de decisión simple.

Si la ganancia de precisión no justifica la pérdida de interpretabilidad, quedarse con el modelo simple.

Distinguir: ¿falla el modelo o fallan los datos?

Cuando un modelo tiene mal desempeño, hay dos causas posibles muy distintas:

Limitación del modelo:

- El algoritmo es inadecuado para la estructura del problema.
- Hiperparámetros mal ajustados.
- Sobreajuste o subajuste.

Solución: cambiar el modelo, ajustar, regularizar.

Limitación del dato:

- La variable objetivo está mal definida o mal medida.
- Las variables predictoras no capturan el fenómeno real.
- Los datos son insuficientes, sesgados o desactualizados.

Solución: mejorar la recolección, redefinir el problema, recolectar más datos.

Error frecuente

Cambiar el modelo cuando el problema es el dato. Ningún algoritmo puede extraer información

El analista como traductor

El analista de datos ocupa una posición única: entiende tanto el lenguaje de los datos como el del dominio.

Traducción técnica $\rightarrow$ dominio:

- “AUC = 0.85” $\rightarrow$ “Detectamos 8 de cada 10 casos relevantes.”
- “Coeficiente $\beta = 0.3$ ” $\rightarrow$ “Un año más de antigüedad se asocia con un 30% más de probabilidad de retención.”
- “Cluster 3” $\rightarrow$ “Clientes jóvenes de alto valor con compras nocturnas.”

Traducción dominio $\rightarrow$ técnica:

- “Queremos predecir quién va a comprar de nuevo” $\rightarrow$ ¿clasificación, regresión, ranking?
- “Necesitamos detectar fraude” $\rightarrow$ ¿cuál es el costo relativo de falsos positivos vs. falsos negativos?
- “¿Por qué el modelo rechazó este caso?” $\rightarrow$ XAI local.

Preguntar bien antes de modelar

Antes de abrir un notebook, hay preguntas que deben responderse:

❶ **¿Cuál es la decisión que se tomará con este análisis?**

No “queremos entender los datos”, sino “si el modelo dice X, haremos Y”.

❷ **¿Cuál es el costo de equivocarse?**

Falso positivo vs. falso negativo: ¿cuál es peor en este contexto?

❸ **¿Los datos disponibles son adecuados para la pregunta?**

Antes de modelar, no después.

❹ **¿Existe ya una solución simple que funcione?**

Si hay una regla de negocio que funciona bien, ¿por qué agregar complejidad?

❺ **¿Cómo se va a usar el modelo en producción?**

Un modelo que nadie implementa no tiene valor.

El ciclo de vida de un proyecto de datos

Fases típicas:

- 1 Definición del problema
- 2 Recolección y exploración de datos
- 3 Preprocesamiento y feature engineering
- 4 Modelado y evaluación
- 5 Interpretación y comunicación
- 6 Despliegue (deployment)
- 7 Monitoreo y mantenimiento

El ciclo no es lineal

En la práctica, se vuelve atrás constantemente. La exploración revela que la pregunta estaba mal formulada.

El modelo revela que los datos tienen errores. El despliegue revela que el contexto cambió.

Iterar no es fracasar: es el proceso normal.

Data drift: cuando el mundo cambia

Un modelo entrenado hoy puede degradarse con el tiempo sin que nadie lo cambie.

¿Por qué?

- **Data drift:** la distribución de las variables de entrada cambia.
Ejemplo: un modelo de precios entrenado antes de una crisis inflacionaria.
- **Concept drift:** la relación entre variables y objetivo cambia.
Ejemplo: patrones de fraude cambian cuando los defraudadores adaptan su comportamiento.

Consecuencia: los modelos en producción deben monitorearse. Las métricas de un modelo no son permanentes.

Regla práctica

Antes de desplegar un modelo, definir cómo y cuándo se va a reevaluar. Un modelo sin monitoreo es una deuda técnica.

- 1 El trabajo real de un analista incluye mucho más que entrenar modelos.
- 2 Los sesgos en los datos se amplifican en los modelos: la “objetividad” del algoritmo es una ilusión.
- 3 No existe una definición única de equidad algorítmica: elegir una implica sacrificar otra.
- 4 Antes de usar ML, preguntar si una solución más simple alcanza.
- 5 Distinguir limitaciones del modelo de limitaciones del dato: son problemas distintos con soluciones distintas.
- 6 El analista traduce entre el lenguaje técnico y el lenguaje del dominio: en ambas direcciones.
- 7 Los modelos en producción se degradan: monitorear no es opcional.