

Métodos de Análisis de Datos I

Unidad 6 – Bloque 5: Portfolio profesional

Departamento de Matemática – UNS

2026

¿Qué es un portfolio?

Un **portfolio** es una colección de proyectos que demuestra lo que sabés hacer con datos reales.

Sí es:

- Evidencia de que podés formular un problema, analizarlo y comunicar resultados.
- Trabajo propio, documentado, reproducible.
- Proyectos con datos reales o realistas, con decisiones justificadas.
- Algo que cualquiera pueda ejecutar y entender sin preguntarte.

No es:

- Una lista de cursos o certificados.
- Código copiado de tutoriales sin adaptación.
- Un proyecto con datos perfectos y resultados obvios.
- Una colección de notebooks sin explicar.

Principio

Un portfolio de 2 proyectos bien hechos vale más que 10 notebooks sin contexto.

GitHub como vitrina profesional

GitHub es el estándar para mostrar trabajo técnico. Un perfil bien organizado comunica mucho antes de que alguien lea una línea de código.

Buenas prácticas en GitHub:

- Cada proyecto en un repositorio propio, con nombre descriptivo.
- **README.md** completo en cada repositorio (ver template más adelante).
- Commits con mensajes que explican qué se hizo, no solo “update”.
- Código comentado: no en cada línea, pero sí en las decisiones no obvias.
- Sin archivos de datos sensibles ni credenciales subidas al repositorio.
- Notebooks con outputs limpios (sin errores ni celdas ejecutadas a medias).

Herramienta complementaria

Un blog personal o perfil en **Kaggle** / **Hugging Face** puede complementar GitHub para proyectos con visualizaciones interactivas o modelos deployados.

Estructura de carpetas recomendada

```
mi_proyecto/  
  README.md  
  data/  
    raw/  
    processed/  
  notebooks/  
    01_exploracion.ipynb  
    02_modelado.ipynb  
    03_resultados.ipynb  
  src/  
    utils.py  
  reports/  
    reporte_final.pdf  
  requirements.txt
```

Notas:

- data/raw/: datos originales, nunca modificados.
- data/processed/: datos limpios listos para modelar.
- Los notebooks se numeran para indicar el orden de ejecución.
- src/ para funciones reutilizables (no repetir código entre notebooks).
- requirements.txt permite reproducir el entorno.

Regla

Si los datos son grandes o sensibles, subir solo

Template: README.md de un proyecto

Secciones mínimas de un buen README:

- ➊ **Título y descripción breve** (2–3 líneas): qué problema resuelve y con qué datos.
- ➋ **Motivación**: por qué el problema es interesante o relevante.
- ➌ **Datos**: origen, tamaño, variables principales.
- ➍ **Metodología**: qué técnicas se usaron y por qué.
- ➎ **Resultados principales**: métrica clave y hallazgo más relevante en 1–2 oraciones.
- ➏ **Cómo ejecutar**: instrucciones claras para reproducir el análisis.
- ➐ **Limitaciones y próximos pasos**.

Criterio simple

Si alguien ajeno al proyecto puede entender qué hiciste, por qué y qué encontraste leyendo solo el README, está bien escrito.

Qué podés mostrar: Unidad 1 – Introducción y EDA

Proyecto sugerido: análisis exploratorio completo de un dataset de interés personal.

Lo que demuestra:

- Capacidad de limpiar datos reales (valores faltantes, outliers, tipos).
- Exploración visual con criterio: no graficar todo, sino lo que responde preguntas.
- Formulación de hipótesis a partir de los datos.

Mini template de notebook:

- ➊ **Celda 1:** contexto del dataset (origen, tamaño, pregunta que guía el EDA).
- ➋ **Celda 2:** carga y revisión inicial (head, info, describe).
- ➌ **Celda 3:** tratamiento de valores faltantes con justificación.
- ➍ **Celda 4:** distribuciones de variables clave (histogramas, boxplots).
- ➎ **Celda 5:** relaciones entre variables (correlación, dispersión).
- ➏ **Celda 6:** síntesis en texto: qué encontré y qué pregunta surge.

Qué podés mostrar: Unidad 2 – Regresión

Proyecto sugerido: predicción de una variable continua con interpretación de coeficientes.

Lo que demuestra:

- Construcción y evaluación de un modelo de regresión lineal o logística.
- Interpretación del significado de cada coeficiente en términos del dominio.
- Verificación de supuestos (linealidad, homocedasticidad, normalidad de residuos).

Mini template de notebook:

- 1 Celda 1: formulación del problema y justificación del modelo.
- 2 Celda 2: preprocesamiento (encoding, escalado si corresponde).
- 3 Celda 3: ajuste del modelo e interpretación de coeficientes.
- 4 Celda 4: gráficos de residuos y verificación de supuestos.
- 5 Celda 5: métricas (R^2 , RMSE, MAE) en train y test.
- 6 Celda 6: conclusión: ¿qué variables importan y cuánto?

Qué podés mostrar: Unidad 3 – Clasificación

Proyecto sugerido: clasificador binario o multiclase con evaluación completa.

Lo que demuestra:

- Manejo del desbalance de clases y elección del umbral de decisión.
- Uso adecuado de métricas (precisión, recall, F1, AUC-ROC) según el contexto.
- Comparación entre al menos dos modelos con justificación de la elección final.

Mini template de notebook:

- 1 Celda 1: descripción del problema y análisis del desbalance de clases.
- 2 Celda 2: pipeline de preprocesamiento con Pipeline de sklearn.
- 3 Celda 3: entrenamiento de dos o más modelos con validación cruzada.
- 4 Celda 4: curva ROC, matriz de confusión, reporte de clasificación.
- 5 Celda 5: análisis del umbral: trade-off precisión/recall.
- 6 Celda 6: justificación del modelo final y sus limitaciones.

Qué podés mostrar: Unidad 4 – Modelos avanzados

Proyecto sugerido: comparación de modelos de ensamble o SVM con optimización de hiperparámetros.

Lo que demuestra:

- Uso de Random Forest, Gradient Boosting o SVM en un problema real.
- Búsqueda sistemática de hiperparámetros (GridSearch, RandomSearch, Optuna).
- Análisis de importancia de variables e interpretación del modelo.

Mini template de notebook:

- ➊ **Celda 1:** justificación de por qué un modelo complejo sobre uno simple.
- ➋ **Celda 2:** línea de base con modelo simple (regresión logística, árbol).
- ➌ **Celda 3:** entrenamiento del modelo avanzado con hiperparámetros por defecto.
- ➍ **Celda 4:** optimización de hiperparámetros y curva de validación.
- ➎ **Celda 5:** importancia de variables y análisis de errores.
- ➏ **Celda 6:** comparación con la línea de base: ¿valió la complejidad?

Qué podés mostrar: Unidad 5 – Aprendizaje no supervisado

Proyecto sugerido: segmentación de entidades con clustering e interpretación de grupos.

Lo que demuestra:

- Aplicación de clustering (K-Means, DBSCAN, jerárquico) con selección justificada del número de grupos.
- Reducción de dimensionalidad (PCA, UMAP) para visualización.
- Interpretación de los clusters en términos del dominio.

Mini template de notebook:

- 1 **Celda 1:** motivación para segmentar (¿qué decisión se toma con los grupos?).
- 2 **Celda 2:** preprocesamiento y escalado (crítico en clustering).
- 3 **Celda 3:** selección del número de clusters (codo, silueta, dendrograma).
- 4 **Celda 4:** visualización en 2D con PCA o UMAP.
- 5 **Celda 5:** perfil de cada cluster (estadísticas descriptivas por grupo).
- 6 **Celda 6:** interpretación: ¿qué nombre le pondrías a cada grupo y por qué?

Errores comunes en portfolios

En el código:

- Notebooks con celdas desordenadas o sin ejecutar de arriba a abajo.
- Variables con nombres `df2`, `X_final2`, `model_v3`.
- Sin separación entre exploración, modelado y evaluación.
- Código repetido que debería estar en funciones.

En el contenido:

- Métricas en entrenamiento sin reportar test.
- Ninguna discusión de limitaciones.
- Conclusiones que no se desprenden del análisis.
- Dataset de Titanic, Iris o tips sin ninguna vuelta de tuerca propia.
- Copiar código de Kaggle sin entenderlo ni adaptarlo.

La señal más clara de un buen proyecto

El analista tomó decisiones y las justificó. No siguió un tutorial: resolvió un problema.

Ideas para llevarse

- 1 Un portfolio demuestra proceso, no solo resultados.
- 2 GitHub es la vitrina estándar: mantenerlo ordenado y documentado.
- 3 Cada proyecto necesita un README que permita entenderlo sin preguntar.
- 4 Cada unidad de la materia es base para un proyecto de portfolio real.
- 5 La estructura del notebook importa: contexto $\rightarrow$ datos $\rightarrow$ análisis $\rightarrow$ conclusión.
- 6 Evitar los datasets cliché sin adaptación propia.
- 7 La señal de un buen analista: tomó decisiones y las justificó.

Para empezar hoy

Elegir un dataset que te interese de verdad. Formular una pregunta concreta. Seguir el template de la unidad más cercana al problema. Documentar cada decisión. Subir a GitHub.